BỘ GIÁO DỤC VÀ ĐÀO TẠO **BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG**

TRƯỜNG ĐẠI HỌC THỦY LỢI



LÊ NGÂN HÀ

THỬ NGHIỆM NỀN TẢNG MESA VỚI CÁC THUẬT TOÁN HỌC TĂNG CƯỜNG

ĐỒ ÁN TỐT NGHIỆP

HÀ NỘI, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG
TRƯỜNG ĐẠI HỌC THỦY LỢI

LÊ NGÂN HÀ

THỬ NGHIỆM NỀN TẢNG MESA VỚI CÁC THUẬT TOÁN HỌC TĂNG CƯỜNG

Ngành: Kỹ thuật phần mềm
Mã số: 7480103

NGƯỜI HƯỚNG DẪN 1. TS. Lê Nguyễn Tuấn Thành

HÀ NỘI, NĂM 2026

	CỘNG HOÀ XÃ HỘI CHỦ NGHĨA VIỆT NAM **Độc lập - Tự do - Hạnh phúc** ----------★---------- **NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP**

Họ tên sinh viên: Lê Ngân Hà — Hệ đào tạo: Đại học chính quy

Lớp: 63KTPM1 — Ngành: Kỹ Thuật Phần Mềm

Khoa: Công Nghệ Thông Tin

1. TÊN ĐỀ TÀI: THỬ NGHIỆM NỀN TẢNG MESA VỚI CÁC THUẬT TOÁN HỌC TĂNG CƯỜNG

2. NỘI DUNG CÁC PHẦN THUYẾT MINH

Nội dung cần thuyết minh	Tỷ lệ (%)
Chương 1: Giới thiệu bài toán	5%
Chương 2: Cơ sở lý thuyết	45%
Chương 3: Cài đặt mô hình	45%
Chương 4: Kết luận và hướng phát triển	5%

3. GIÁO VIÊN HƯỚNG DẪN TỪNG PHẦN

Phần	Họ tên giáo viên hướng dẫn
Chương 1: Giới thiệu bài toán	TS. Lê Nguyễn Tuấn Thành
Chương 2: Cơ sở lý thuyết	
Chương 3: Cài đặt mô hình	
Chương 4: Kết luận và hướng phát triển	

4. NGÀY GIAO NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Ngày ..... tháng ..... năm 2025

Trưởng Bộ môn	**Giáo viên hướng dẫn chính**
(Ký và ghi rõ Họ tên)	*(Ký và ghi rõ Họ tên)*
	TS. Lê Nguyễn Tuấn Thành

Nhiệm vụ Đồ án tốt nghiệp đã được Hội đồng thi tốt nghiệp của Khoa thông qua

Ngày ..... tháng ..... năm 2026

Chủ tịch Hội đồng

(Ký và ghi rõ Họ tên)

Sinh viên đã hoàn thành và nộp bản Đồ án tốt nghiệp cho Hội đồng thi ngày…..tháng….. năm 2026

Sinh viên làm Đồ án tốt nghiệp

(Ký và ghi rõ Họ tên)

Lê Ngân Hà

TRƯỜNG ĐẠI HỌC THUỶ LỢI

KHOA CÔNG NGHỆ THÔNG TIN

.

BẢN TÓM TẮT ĐỀ CƯƠNG ĐỒ ÁN TỐT NGHIỆP

Tên đề tài: Thử nghiệm nền tảng Mesa với các thuật toán học tăng cường

Sinh viên thực hiện: Lê Ngân Hà

Lớp: 63KTPM1

Mã sinh viên: 2151170580

Số điện thoại: 0916066372

Email: 2151170580@e.tlu.edu.vn

Giáo viên hướng dẫn: <GVHD1> TS. Lê Nguyễn Tuấn Thành

TÓM TẮT ĐỀ TÀI

Đề tài sử dụng lại mô hình có sẵn "Virus on a Network" từ thư viện Mesa trong Python để mô phỏng quá trình lây lan của virus trên mạng lưới và cải tiến mô hình từ SIR gốc (Susceptible - Infectious – Recovered) sang mô hình SIRV (Susceptible - Infectious - Recovered - Vaccinated). Trong mô hình, mỗi cá thể được biểu diễn như một nút trong mạng, và virus lây lan thông qua các kết nối giữa các cá thể có tiếp xúc. Trên cơ sở đó, đề tài kết hợp thuật toán học tăng cường (Reinforcement Learning - RL) nhằm tìm ra chiến lược can thiệp tối ưu giúp hạn chế sự lây lan của virus. Mục tiêu hướng đến là xây dựng một mô hình mô phỏng có khả năng học hỏi và hỗ trợ ra quyết định trong việc kiểm soát sự lây lan của virus trên mạng

CÁC MỤC TIÊU CHÍNH

- Sử dụng lại mô hình mẫu "Virus on a Network" từ thư viện Mesa để mô phỏng sự lây lan của virus.
- Thiết kế, cải tiến và mô hình hóa bài toán học tăng cường.
- Tích hợp mô hình Mesa với môi trường học tăng cường.

- Huấn luyện, so sánh và đánh giá mô hình học tăng cường.
- Phân tích, trực quan hóa và đánh giá kết quả mô phỏng.

KẾT QUẢ DỰ KIẾN

- Một mô hình mô phỏng hoàn chỉnh quá trình lây lan virus của mô hình Virus on Network sử dụng Mesa.
- Một môi trường học tăng cường chuẩn hóa cho bài toán kiểm soát dịch bệnh.
- Một thuật toán học tăng cường được huấn luyện có khả năng tìm ra chính sách can thiệp tối ưu, hiệu quả.

KẾ HOẠCH THỰC HIỆN

Thời gian	Công việc
Tháng 10	- Nghiên cứu tổng quan về mô hình SIR và SIRV, thuật toán học tăng cường và Mesa. - Xây dựng mô hình "Virus on Network" bằng Mesa và kiểm thử mô phỏng cơ bản.
Tháng 11	- Xây dựng môi trường học tăng cường tương tác với mô hình Mesa. - Thiết kế cấu trúc trạng thái, hành động và hàm phần thưởng. - Thử nghiệm với thuật toán tăng cường RL.
Tháng 12	- Đánh giá kết quả và so sánh mô hình không có RL và có RL. - Trực quan hóa và viết báo cáo kết quả.

TÀI LIỆU THAM KHẢO

[1]. Mesa Documentation – *Agent-Based Modeling in Python* https://mesa.readthedocs.io

[2]. Mesa core example: *Virus on a Network* https://mesa.readthedocs.io/latest/examples/basic/virus_on_network.html

[3]. NetLogo Model: *Virus on a Network* – Center for Connected Learning and Computer-Based Modeling, Northwestern University.

[4]. Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.

[5]. Kermack, W. O., & McKendrick, A. G. (1927). *A Contribution to the Mathematical Theory of Epidemics*. Proceedings of the Royal Society A.

[6]. Pastor-Satorras, R., Castellano, C., Van Mieghem, P., & Vespignani, A. (2015). "Epidemic processes in complex networks." *Reviews of Modern Physics*, 87(3), 925–979.

GÁY BÌA ĐỒ ÁN TỐT NGHIỆP, KHÓA LUẬN TỐT NGHIỆP

HỌ VÀ TÊN

ĐỒ ÁN/KL TỐT NGHIỆP

HÀ NỘI, NĂM

LỜI CAM ĐOAN

Em xin cam đoan đây là Đồ án tốt nghiệp của bản thân. Các kết quả trong Đồ án tốt nghiệp này là trung thực, và không sao chép từ bất kỳ một nguồn nào và dưới bất kỳ hình thức nào. Việc tham khảo các nguồn tài liệu đã được thực hiện trích dẫn và ghi nguồn tài liệu tham khảo đúng quy định.

Tác giả ĐATN

Lê Ngân Hà

LỜI CÁM ƠN

Đầu tiên, em xin bày tỏ lòng biết ơn đến TS. Lê Nguyễn Tuấn Thành - Giảng viên của Khoa CNTT - Trường Đại học Thủy Lợi đã tận tình hướng dẫn, hỗ trợ và chỉ hướng em trong suốt quá trình thực hiện đồ án tốt nghiệp. Những ý kiến và sự chỉ bảo của thầy đã giúp em hoàn thành đề tài: "Thử nghiệm nền tảng Mesa với thuật toán học tăng cường".

Tiếp đó, em chân thành cảm ơn toàn thể quý Thầy, Cô trong Khoa Công nghệ Thông tin – Trường Đại học Thủy Lợi. Chính sự tâm huyết, kiến thức chuyên môn vững vàng và môi trường học tập thân thiện mà các Thầy Cô đã kiến tạo là nền tảng quan trọng giúp em tích lũy kỹ năng, phát triển tư duy và định hướng rõ ràng hơn cho con đường học tập và nghề nghiệp của mình.

Đồ án tốt nghiệp này là thành quả của cả một quá trình học hỏi, nỗ lực không ngừng nghỉ, đồng thời là sự kết tinh của sự hỗ trợ, khích lệ từ Thầy Cô, bạn bè và gia đình. Tuy em đã cố gắng để hoàn thiện nhất, nhưng do hạn chế về thời gian và kinh nghiệm, chắc chắn đồ án này của em vẫn còn nhiều điểm thiếu sót và chưa hoàn hảo. Em kính mong nhận được sự góp ý chân thành từ Quý Thầy Cô để em có thể hoàn thiện hơn không chỉ đồ án này mà còn trong những bước đi tiếp theo trên con đường học tập và nghiên cứu.

Em xin chân thành cảm ơn!

MỤC LỤC

DANH MỤC CÁC HÌNH ẢNH vi
DANH MỤC BẢNG BIỂU vii
DANH MỤC CÁC TỪ VIẾT TẮT VÀ GIẢI THÍCH CÁC THUẬT NGỮ viii
MỞ ĐẦU xii
CHƯƠNG 1 GIỚI THIỆU BÀI TOÁN 1
1.1 Mô tả bài toán 1
1.2 Lý do chọn đề tài 1
1.3 Khảo sát các nghiên cứu khoa học liên quan 3
1.3.1 Nghiên cứu bài toán điều khiển dịch bệnh ở quy mô lớn 3
1.3.2 Nghiên cứu cân bằng giữa kiểm soát dịch bệnh và chi phí xã hội 4
1.4 Mục tiêu đề tài 5
1.5 Đối tượng, phạm vi nghiên cứu 5
1.5.1 Đối tượng nghiên cứu 5
1.5.2 Phạm vi nghiên cứu 6
1.5.3 Công cụ và giải pháp triển khai 6
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT 9
2.1 Học máy 9
2.1.1 Tổng quan 9
2.1.2 Phân loại kỹ thuật học máy 10
2.2 Học tăng cường 10
2.2.1 Tổng quan 10
2.2.2 Lợi ích của học tăng cường 12
2.2.3 Các bài toán áp dụng học tăng cường 12
2.2.4 Mô hình Markov Decision Process (MDP) 13
2.2.5 Một số thuật toán học tăng cường 14
2.3 Mô phỏng dựa trên tác tử (Agent-Based Modeling) 18
2.3.1 Khái niệm 18
2.3.2 Thành phần cơ bản 18
2.3.3 Ứng dụng 19

2.4 Nền tảng Mesa 20
2.4.1 Giới thiệu về Mesa 20
2.4.2 Kiến trúc cơ bản của Mesa 20
2.4.3 Ưu điểm của Mesa trong nghiên cứu mô phỏng 21
2.5 Mô hình Virus on Network 21
2.5.1 Tổng quan mô hình Virus on Network 21
2.5.2 Mô hình SIR cổ điển 22
2.5.3 Mô hình Virus on Network trong Mesa 23
2.5.4 Mô hình SIRV 24
2.5.5 So sánh SIR và SIRV 25
2.6 Kết hợp học tăng cường với mô phỏng trên Mesa 26
2.6.1 Động cơ kết hợp học tăng cường và ABM 26
2.6.2 Vai trò của tác tử học tăng cường trong mô hình 26
2.6.3 Lợi ích của việc áp dụng học tăng cường trong mô phỏng dịch bệnh 27
CHƯƠNG 3 CÀI ĐẶT MÔ HÌNH 29
3.1 Tổng quan 29
3.1.1 Phương pháp mô phỏng dịch bệnh (SIRV trên mạng lưới) 29
3.1.2 Phương pháp học tăng cường cho bài toán điều khiển 30
3.1.3 Yêu cầu chức năng 31
3.1.4 Yêu cầu phi chức năng 31
3.2 Thiết kế mô hình 32
3.2.1 Thiết kế mô hình SIRV 32
3.2.2 Thiết kế tác tử (Agent) 33
3.2.3 Thiết kế mạng lưới tiếp xúc 35
3.2.4 Thiết kế và chuẩn bị dữ liệu mô phỏng 36
3.3 Thiết kế môi trường học tăng cường 37
3.3.1 Xây dựng môi trường theo chuẩn OpenAI Gym 37
3.3.2 Không gian trạng thái (State Space) 38
3.3.3 Không gian hành động (Action Space) 39
3.3.4 Hàm phần thưởng (Reward Function) 40

3.3.5 Mô hình hóa quá trình lây nhiễm 43
3.3.6 Biểu diễn và chuẩn hóa trạng thái cho học tăng cường 44
3.4 Thiết kế và tích hợp thuật toán học tăng cường 44
3.4.1 Lựa chọn thuật toán DQN 44
3.4.2 Kiến trúc mạng nơ-ron 45
3.4.3 Quy trình huấn luyện tác tử học tăng cường 46
3.5 Quy trình mô phỏng và huấn luyện tổng thể 48
3.5.1 Luồng dữ liệu tổng thể của mô hình 48
3.5.2 Vai trò của từng thành phần trong chu trình 49
3.5.3 Chu trình khép kín mô phỏng – học tập 50
3.6 Cài đặt mô hình và huấn luyện mô hình SIRV 51
3.6.1 Cài đặt môi trường mô phỏng và môi trường học tăng cường 51
3.6.2 Quy trình huấn luyện tác tử học tăng cường 54
3.6.3 Thay đổi và khảo sát các tham số mô phỏng 60
3.7 So sánh và đánh giá 61
3.7.1 So sánh định tính 61
3.7.2 So sánh định lượng dựa trên kết quả mô phỏng 62
3.7.3 Đánh giá vai trò của học tăng cường 62
3.7.4 Nhận xét tổng quát 63
CHƯƠNG 4 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 64
4.1 Kết luận 64
4.2 Hướng phát triển 65
TÀI LIỆU THAM KHẢO 67

DANH MỤC CÁC HÌNH ẢNH

Hình 2.1 Mô hình quan hệ giữa Artificial Intelligence (AI), Machine Learning (ML) và Deep Learning (DL) 9

Hình 2.2 Mô hình học tăng cường 11

Hình 2.3 Mô hình tương tác giữa tác tử và môi trường trong bài toán học tăng cường (MDP) 14

Hình 2.4 Kiến trúc hoạt động cơ bản của thuật toán Q-learning 15

Hình 2.5 Kiến trúc thuật toán DQN 16

Hình 2.6 Kiến trúc thuật toán Actor-Critic 17

Hình 2.7 Các thành phần chính trong mô hình mô phỏng dựa trên tác tử (Agent-Based Modeling) 18

Hình 2.8 Mô hình SIR 22

Hình 3.1 Quá trình lây nhiễm của S (Susceptible) dựa trên xác suất lây truyền 33

Hình 3.2 Kiến trúc thuật toán Deep Q-learning 45

Hình 3.3 Sơ đồ luồng xử lý 49

Hình 3.4 Sơ đồ chu trình khép kín mô phỏng - học tập giữa tác tử học tăng cường và môi trường mô phỏng dịch bệnh 51

Hình 3.5 Câu lệnh hàm reset và step 54

Hình 3.6 Diễn biến trong kịch bản không sử dụng học tăng cường 56

Hình 3.7 Diễn biến trong kịch bản sử dụng học tăng cường 59

DANH MỤC BẢNG BIỂU

Bảng 2.1 Bảng so sánh mô hình SIR và SIRV 25

Bảng 3.1. Phân tích kết quả mô phỏng kịch bản không sử dụng học tăng cường (Baseline) 56

Bảng 3.2 Phân tích kết quả mô phỏng kịch bản sử dụng học tăng cường (RL) 59

Bảng 3.3 So sánh hiệu quả kiểm soát dịch bệnh giữa mô hình không sử dụng RL và có sử dụng RL 61

DANH MỤC CÁC TỪ VIẾT TẮT VÀ GIẢI THÍCH CÁC THUẬT NGỮ

ABM (Agent-Based Modeling): Mô phỏng dựa trên tác tử – phương pháp mô phỏng hệ thống phức tạp thông qua các tác tử độc lập tương tác với nhau.

Action (Hành động): Lựa chọn mà tác tử thực hiện dựa trên trạng thái quan sát được.

Actor–Critic: Nhóm thuật toán học tăng cường kết hợp giữa học chính sách (Actor) và học hàm giá trị (Critic).

Agent (Tác tử): Thực thể ra quyết định trong mô hình, có trạng thái riêng và khả năng thực hiện hành động.

AI (Artificial Intelligence): Trí tuệ nhân tạo – lĩnh vực nghiên cứu và phát triển các hệ thống có khả năng mô phỏng trí thông minh của con người.

Baseline: Kịch bản mô phỏng không sử dụng học tăng cường để làm mốc so sánh.

Closed-loop Simulation–Learning (Chu trình khép kín mô phỏng – học tập): Quy trình lặp giữa mô phỏng, học và cập nhật chính sách của tác tử học tăng cường.

CPU (Central Processing Unit): Bộ xử lý trung tâm của máy tính.

Data Collector: Thành phần thu thập dữ liệu trong quá trình mô phỏng.

DL (Deep Learning): Học sâu – nhánh của học máy sử dụng mạng nơ-ron nhiều lớp để xử lý dữ liệu phức tạp.

DQN (Deep Q-Network): Thuật toán học tăng cường sử dụng mạng nơ-ron sâu để xấp xỉ hàm Q.

Edge (Cạnh): Biểu diễn mối quan hệ tiếp xúc giữa hai cá thể.

Environment (Môi trường): Không gian mà tác tử tương tác, bao gồm các quy tắc chuyển trạng thái và cơ chế phản hồi phần thưởng.

Global Policy (Chính sách toàn cục): Chính sách can thiệp tác động đến toàn bộ hệ thống.

Gym (OpenAI Gym): Thư viện cung cấp giao diện chuẩn cho môi trường học tăng cường.

Infected (I): Trạng thái cá thể đang nhiễm bệnh và có khả năng lây nhiễm.

Infection Rate (Tỷ lệ lây nhiễm): Xác suất cá thể bị nhiễm khi tiếp xúc với cá thể nhiễm bệnh.

Markov Property (Tính chất Markov): Giả định rằng trạng thái tiếp theo chỉ phụ thuộc vào trạng thái hiện tại và hành động, không phụ thuộc lịch sử trước đó.

MDP (Markov Decision Process): Quy trình ra quyết định Markov – mô hình toán học nền tảng của học tăng cường.

Mesa: Nền tảng mã nguồn mở bằng Python dùng để xây dựng mô hình mô phỏng dựa trên tác tử.

ML (Machine Learning): Học máy – nhánh của trí tuệ nhân tạo cho phép hệ thống tự học từ dữ liệu mà không cần lập trình chi tiết từng quy tắc.

Network (Mạng lưới): Cấu trúc gồm các nút và cạnh biểu diễn mối quan hệ tiếp xúc.

NetworkX: Thư viện Python hỗ trợ xây dựng và xử lý mạng lưới.

Neural Network (Mạng nơ-ron): Mô hình học máy mô phỏng cấu trúc thần kinh sinh học, dùng trong DQN để ước lượng giá trị Q.

Node (Nút): Đại diện cho một cá thể trong mạng lưới.

Policy (Chính sách): Quy tắc ánh xạ từ trạng thái sang hành động, thể hiện chiến lược ra quyết định của tác tử.

Q-learning: Thuật toán học tăng cường không mô hình, dùng để học hàm giá trị hành động Q(s, a).

Q-table: Bảng lưu trữ giá trị Q cho mọi cặp trạng thái – hành động trong Q-learning truyền thống.

Q-value (Giá trị Q): Giá trị kỳ vọng của tổng phần thưởng khi thực hiện hành động a tại trạng thái s.

Recovery Rate (Tỷ lệ hồi phục): Xác suất cá thể hồi phục sau một khoảng thời gian nhiễm bệnh.

Replay Memory: Bộ nhớ lưu trữ các trải nghiệm (s, a, r, s') nhằm ổn định quá trình huấn luyện DQN.

Reward (Phần thưởng): Tín hiệu phản hồi từ môi trường nhằm đánh giá chất lượng hành động của tác tử.

RL (Reinforcement Learning): Học tăng cường – phương pháp học trong đó tác tử học cách ra quyết định thông qua tương tác với môi trường và phần thưởng.

Scheduler: Thành phần điều phối thứ tự thực thi các tác tử trong Mesa.

Simulation (Mô phỏng): Quá trình tái hiện hành vi của hệ thống theo thời gian dựa trên mô hình.

SIR (Susceptible – Infected – Recovered): Mô hình dịch tễ học cổ điển gồm ba trạng thái nhạy cảm, nhiễm bệnh và hồi phục.

SIRV (Susceptible – Infected – Recovered – Vaccinated): Mô hình mở rộng của SIR, bổ sung trạng thái đã tiêm vaccine.

State (Trạng thái): Biểu diễn tình trạng hiện tại của môi trường tại một thời điểm nhất định.

Susceptible (S): Trạng thái cá thể có nguy cơ bị nhiễm bệnh.

Target Network: Mạng nơ-ron mục tiêu dùng trong DQN để giảm dao động và tăng tính ổn định khi cập nhật trọng số.

Time Step (Bước thời gian): Đơn vị thời gian rời rạc trong mô phỏng.

Vaccinated (V): Trạng thái cá thể đã được tiêm vaccine, có xác suất nhiễm bệnh thấp hơn.

Virus on a Network: Mô hình mô phỏng sự lây lan virus trên mạng lưới tiếp xúc giữa các cá thể.

MỞ ĐẦU

Trong bối cảnh khoa học dữ liệu và trí tuệ nhân tạo ngày càng phát triển, việc mô phỏng và phân tích các hệ thống phức tạp có vai trò quan trọng trong nhiều lĩnh vực nghiên cứu và ứng dụng. Các hệ thống gồm nhiều cá thể tương tác thường có hành vi khó dự đoán nếu chỉ sử dụng các mô hình truyền thống, do đó cần những phương pháp mô phỏng linh hoạt hơn để phản ánh sát thực tế.

Mô phỏng tác tử (Agent-Based Modeling) là một hướng tiếp cận hiệu quả cho các bài toán trên, cho phép mô hình hóa từng cá thể như một tác tử độc lập tương tác trong môi trường chung. Mesa là một nền tảng mã nguồn mở phổ biến trong Python, hỗ trợ xây dựng các mô hình mô phỏng tác tử với khả năng mở rộng cao. Tuy nhiên, trong nhiều mô hình, các quy tắc điều khiển vẫn chủ yếu được thiết kế thủ công, làm hạn chế khả năng thích nghi của hệ thống trước những thay đổi động của môi trường.

Học tăng cường (Reinforcement Learning) là một nhánh của trí tuệ nhân tạo cho phép tác tử tự học chiến lược hành động thông qua tương tác với môi trường và phản hồi dưới dạng phần thưởng. Việc kết hợp học tăng cường với các nền tảng mô phỏng tác tử mở ra khả năng xây dựng các chính sách điều khiển linh hoạt và thích nghi hơn so với các phương pháp truyền thống.

Xuất phát từ đó, đồ án tốt nghiệp “Thử nghiệm nền tảng Mesa với các thuật toán học tăng cường” được thực hiện nhằm nghiên cứu khả năng tích hợp các thuật toán học tăng cường vào nền tảng Mesa thông qua một môi trường mô phỏng cụ thể. Đồ án tập trung đánh giá hiệu quả của các chính sách học được, đồng thời phân tích ưu điểm và hạn chế của cách tiếp cận này, từ đó đề xuất các hướng nghiên cứu và phát triển trong tương lai.

CHƯƠNG 1 GIỚI THIỆU BÀI TOÁN

1.1 Mô tả bài toán

Dịch bệnh truyền nhiễm là một trong những thách thức lớn đối với xã hội hiện đại, điển hình là đại dịch COVID-19 đã bùng phát trên phạm vi toàn cầu và gây ảnh hưởng nghiêm trọng đến đời sống kinh tế – xã hội, trong đó có Việt Nam. Một trong những vấn đề cốt lõi trong nghiên cứu dịch tễ học là hiểu rõ cơ chế lây lan của virus trong cộng đồng cũng như đánh giá hiệu quả của các biện pháp can thiệp nhằm kiểm soát dịch bệnh.

Trong đề tài này, bài toán được đặt ra là mô phỏng quá trình lây lan của virus trong một mạng lưới các cá thể, nơi mỗi cá thể được xem như một tác tử độc lập và có thể tương tác với các cá thể khác thông qua các mối quan hệ tiếp xúc. Trạng thái sức khỏe của mỗi cá thể được mô tả theo mô hình SIRV, bao gồm các trạng thái: nhạy cảm (Susceptible), nhiễm bệnh (Infected), hồi phục (Recovered) và đã tiêm vaccine (Vaccinated).

Trên cơ sở mô hình mô phỏng này, đề tài tập trung nghiên cứu khả năng áp dụng các thuật toán học tăng cường để xây dựng một tác tử điều khiển có khả năng quan sát trạng thái của hệ thống và đưa ra các quyết định can thiệp theo từng bước thời gian. Mục tiêu của tác tử học tăng cường là học được chính sách hành động phù hợp nhằm hạn chế sự lây lan của dịch bệnh trong mạng lưới.

Bài toán được xây dựng dựa trên mô hình "Virus on Network" mang tính khái quát, lấy cảm hứng từ bối cảnh dịch COVID-19 đã từng xảy ra trên thế giới và tại Việt Nam. Tuy nhiên, mô hình trong đề tài không nhằm tái hiện chính xác một kịch bản dịch bệnh cụ thể mà tập trung vào việc khảo sát và thử nghiệm phương pháp kết hợp giữa mô phỏng tác tử và học tăng cường.

1.2 Lý do chọn đề tài

Trong những năm gần đây, mô phỏng dựa trên tác tử (Agent-Based Modeling – ABM) ngày càng được sử dụng rộng rãi trong nhiều lĩnh vực như kinh tế, xã hội, giao thông và đặc biệt là mô phỏng sự lây lan của dịch bệnh truyền nhiễm. Phương pháp này cho phép mô hình hóa hành vi của từng cá thể riêng lẻ cũng như sự tương tác giữa các cá thể trong

một hệ thống phức tạp, từ đó phản ánh tốt hơn các hiện tượng phát sinh so với các mô hình trung bình truyền thống.

Đối với các chuyên gia y tế công cộng và các nhà dịch tễ học, mô phỏng giống như một quả cầu pha lê. Nó cho phép chúng ta thấy trước khả năng lây lan của bệnh tật trong nhiều trường hợp và lựa chọn điều trị khác nhau. Những mô hình này hỗ trợ việc ra quyết định, phân bổ nguồn lực hiệu quả và hiểu rõ tác động tiềm ẩn của các kỹ thuật khác nhau.

Trong lĩnh vực mô phỏng dịch bệnh, cách tiếp cận Virus-on-Network đã thu hút nhiều sự quan tâm nhờ khả năng biểu diễn quá trình lây lan thông qua mạng lưới tiếp xúc xã hội. Mỗi cá thể được mô hình hóa như một nút trong mạng, trong khi các cạnh thể hiện mối quan hệ tiếp xúc có khả năng dẫn đến lây nhiễm. Cách mô hình hóa này giúp phản ánh chân thực hơn cấu trúc xã hội và sự không đồng nhất trong hành vi tiếp xúc của con người.

Thực tiễn đại dịch COVID-19 bùng phát trên phạm vi toàn cầu trong giai đoạn 2019–2022 đã cho thấy rõ tầm quan trọng của việc nghiên cứu sự lây lan dịch bệnh trên mạng lưới tiếp xúc. Tại nhiều quốc gia, trong đó có Việt Nam, các biện pháp can thiệp như giãn cách xã hội, phong tỏa, hạn chế đi lại và triển khai tiêm chủng vaccine theo từng giai đoạn đã ảnh hưởng mạnh mẽ đến diễn biến dịch bệnh cũng như đời sống kinh tế - xã hội. Những quyết định này thường phải được đưa ra trong điều kiện thông tin không đầy đủ và tồn tại sự đánh đổi giữa kiểm soát dịch bệnh và chi phí xã hội.

Mesa là một nền tảng mã nguồn mở phổ biến trong Python, hỗ trợ xây dựng các mô hình mô phỏng tác tử với khả năng mở rộng linh hoạt và tích hợp thuận tiện với các thư viện khoa học dữ liệu. Tuy nhiên, phần lớn các mô hình xây dựng trên Mesa hiện nay vẫn sử dụng các chính sách điều khiển cố định hoặc được thiết kế thủ công, chưa khai thác đầy đủ tiềm năng của các thuật toán học máy trong việc đưa ra quyết định thích nghi theo trạng thái của hệ thống.

Song song với đó, học tăng cường (Reinforcement Learning – RL) là một nhánh quan trọng của học máy, cho phép một tác tử tự học chiến lược hành động tối ưu thông qua

tương tác với môi trường và phản hồi dưới dạng phần thưởng. Học tăng cường đã được ứng dụng thành công trong nhiều bài toán điều khiển và tối ưu, tuy nhiên việc kết hợp RL với các nền tảng mô phỏng tác tử như Mesa vẫn còn nhiều dư địa để nghiên cứu và thử nghiệm.

Xuất phát từ những lý do trên, đề tài "Thử nghiệm nền tảng Mesa với các thuật toán học tăng cường" được thực hiện nhằm khảo sát khả năng tích hợp giữa mô phỏng tác tử và học tăng cường trong một bài toán mô phỏng cụ thể. Thông qua việc xây dựng một mô hình mô phỏng dịch bệnh theo hướng Virus-on-Network và cho tác tử học tăng cường tương tác trực tiếp với mô hình, đồ án hướng tới việc đánh giá tính khả thi, hiệu quả và những hạn chế của cách tiếp cận này trong bối cảnh thực tiễn.

1.3 Khảo sát các nghiên cứu khoa học liên quan

1.3.1 Nghiên cứu bài toán điều khiển dịch bệnh ở quy mô lớn

Một hướng nghiên cứu tiêu biểu trong việc ứng dụng học tăng cường vào bài toán kiểm soát dịch bệnh được trình bày trong bài báo *"Deep Reinforcement Learning for Large-Scale Epidemic Control"* công bố tại hội thảo ALA 2020. Trong nghiên cứu này, tác giả tập trung vào bài toán điều khiển dịch bệnh ở quy mô lớn bằng cách sử dụng các thuật toán học tăng cường sâu, tiêu biểu là Proximal Policy Optimization (PPO). Mô hình dịch bệnh được xây dựng theo dạng phân vùng (patch-based), trong đó mỗi vùng đại diện cho một khu vực địa lý với các tham số dịch tễ riêng biệt. Tác nhân học tăng cường có nhiệm vụ đưa ra các quyết định can thiệp như đóng hoặc mở trường học nhằm giảm thiểu tốc độ lây lan của dịch bệnh.

Điểm nổi bật của nghiên cứu này là khả năng xử lý không gian trạng thái lớn và phức tạp, đồng thời cho thấy học tăng cường có thể học được các chính sách can thiệp hiệu quả mà không cần thiết kế thủ công các luật điều khiển. Tuy nhiên, mô hình được sử dụng chủ yếu ở mức tổng quát theo vùng, chưa đi sâu vào mô phỏng chi tiết hành vi và tương tác của từng cá thể trong mạng lưới tiếp xúc.

So với nghiên cứu trên, đồ án này lựa chọn tiếp cận theo hướng mô phỏng dựa trên tác tử (Agent-Based Modeling), trong đó mỗi cá thể được mô hình hóa trực tiếp như một

node trong mạng lưới tiếp xúc. Việc kết hợp học tăng cường với mô hình tác tử trên nền tảng Mesa cho phép mô phỏng chi tiết hơn quá trình lây lan và phản ánh tốt hơn các tương tác cục bộ giữa các cá thể. Ngoài ra, đồ án mở rộng mô hình dịch bệnh từ SIR sang SIRV, bổ sung yếu tố tiêm vaccine – một khía cạnh chưa được nhấn mạnh trong nghiên cứu của ALA 2020.

1.3.2 Nghiên cứu cân bằng giữa kiểm soát dịch bệnh và chi phí xã hội

Một nghiên cứu khác có ảnh hưởng lớn trong lĩnh vực này là bài báo *"Exploring optimal control of epidemic spread using reinforcement learning"* được công bố trên tạp chí Scientific Reports năm 2023. Nghiên cứu này tập trung vào việc thiết kế một môi trường mô phỏng trong đó tác nhân học tăng cường phải cân bằng giữa hai mục tiêu đối lập: kiểm soát sự lây lan của dịch bệnh và giảm thiểu tác động tiêu cực đến kinh tế – xã hội. Trong mô hình, mỗi cá thể vừa đóng vai trò là nguồn lây nhiễm, vừa tham gia vào hoạt động kinh tế, và các biện pháp hạn chế di chuyển sẽ ảnh hưởng trực tiếp đến cả hai yếu tố này.

Điểm mạnh của nghiên cứu là cách thiết kế hàm phần thưởng, trong đó chi phí can thiệp được tích hợp rõ ràng cùng với số ca nhiễm và tử vong. Nhờ đó, tác nhân học tăng cường có thể tự động điều chỉnh mức độ can thiệp theo từng giai đoạn của dịch bệnh, chuyển từ ưu tiên phát triển kinh tế sang ưu tiên kiểm soát dịch khi số ca nhiễm vượt ngưỡng nguy hiểm.

Đồ án này kế thừa tinh thần tiếp cận đó khi thiết kế hàm phần thưởng cho tác nhân học tăng cường, trong đó chính sách lockdown được đánh đổi giữa việc giảm số ca nhiễm và chi phí xã hội của can thiệp. Tuy nhiên, thay vì mô hình hóa kinh tế một cách trực tiếp, đồ án tập trung vào mô hình mạng lưới tiếp xúc và yếu tố tiêm vaccine, phản ánh sát hơn bối cảnh dịch COVID-19 trong thực tế. Đồng thời, tác nhân học tăng cường trong đồ án chỉ điều khiển chính sách can thiệp ở mức toàn cục, không can thiệp trực tiếp vào hành vi từng cá thể, giúp đơn giản hóa không gian hành động và phù hợp với các quyết định ở cấp độ chính sách công.

1.4 Mục tiêu đề tài

Mục tiêu tổng quát của đề tài là nghiên cứu khả năng ứng dụng các thuật toán học tăng cường trong môi trường mô phỏng tác tử được xây dựng trên nền tảng Mesa, thông qua một bài toán mô phỏng sự lây lan dịch bệnh trên mạng lưới tiếp xúc xã hội. Các mục tiêu cụ thể của đề tài bao gồm:

- Nghiên cứu các khái niệm và phương pháp liên quan đến mô phỏng tác tử, mô hình dịch bệnh trên mạng lưới và học tăng cường.
- Xây dựng một mô hình mô phỏng trên nền tảng Mesa, trong đó các tác tử đại diện cho cá thể trong cộng đồng và tương tác với nhau thông qua mạng lưới tiếp xúc.
- Mô hình hóa quá trình lây lan dịch bệnh theo hướng Virus-on-Network, kết hợp với mô hình SIRV nhằm phản ánh vai trò của tiêm chủng vaccine theo thời gian.
- Thiết kế và triển khai một tác tử học tăng cường có khả năng quan sát trạng thái của hệ thống và đưa ra quyết định điều khiển phù hợp.
- Thực hiện các thí nghiệm mô phỏng nhằm so sánh kết quả giữa các kịch bản sử dụng và không sử dụng học tăng cường.
- Phân tích kết quả thu được để làm rõ ưu điểm, hạn chế và tiềm năng ứng dụng của việc kết hợp học tăng cường với mô phỏng tác tử trên nền tảng Mesa.

1.5 Đối tượng, phạm vi nghiên cứu

1.5.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là quá trình mô phỏng sự lây lan dịch bệnh truyền nhiễm trong một cộng đồng được biểu diễn dưới dạng mạng lưới tiếp xúc xã hội. Trong mô hình này, mỗi cá thể được biểu diễn bởi một tác tử với trạng thái dịch bệnh cụ thể và tương tác với các tác tử khác thông qua các mối quan hệ tiếp xúc.

Cùng với đó, đề tài cũng tập trung nghiên cứu hành vi ra quyết định của tác tử học tăng cường trong vai trò điều khiển chính sách can thiệp, nhằm tác động gián tiếp đến diễn biến của hệ thống mô phỏng.

1.5.2 Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu việc kết hợp mô phỏng tác tử và học tăng cường trong một bài toán mô phỏng cụ thể. Phạm vi nghiên cứu của đề tài được giới hạn trong các nội dung sau:

- Mô hình mô phỏng: Mô hình được xây dựng với mục đích nghiên cứu và thử nghiệm, không nhằm tái hiện chính xác số liệu dịch bệnh COVID-19 tại Việt Nam hay trên thế giới.
- Dữ liệu: Các tham số dịch tễ và mạng lưới tiếp xúc được lựa chọn ở mức hợp lý để phản ánh xu hướng chung của quá trình lây lan.
- Phương pháp kỹ thuật: Các thuật toán học tăng cường được sử dụng ở mức cơ bản và trung bình, tập trung vào việc đánh giá khả năng tích hợp với Mesa hơn là tối ưu hiệu suất tuyệt đối.
- Đánh giá, kết quả mô hình: Chủ yếu mang tính định tính và so sánh giữa các kịch bản mô phỏng, phục vụ cho mục tiêu nghiên cứu phương pháp.

1.5.3 Công cụ và giải pháp triển khai

Để thực hiện đề tài, các công cụ và giải pháp kỹ thuật được lựa chọn nhằm đảm bảo tính phù hợp với mục tiêu nghiên cứu và khả năng triển khai thực tế:

1. Công cụ phần mềm

- Ngôn ngữ lập trình: Python, với ưu thế về khả năng hỗ trợ mô phỏng, xử lý dữ liệu và học máy.

- Các thư viện và nền tảng sử dụng:

- Mesa: dùng để xây dựng và quản lý mô hình mô phỏng tác tử.

- NetworkX: hỗ trợ xây dựng và xử lý cấu trúc mạng lưới tương tác giữa các tác tử.
- Gym: cung cấp giao diện chuẩn cho môi trường học tăng cường, cho phép tác tử tương tác với mô hình Mesa.
- Stable-Baselines3: được sử dụng để triển khai và huấn luyện thuật toán học tăng cường DQN (PyTorch được sử dụng gián tiếp thông qua thư viện Stable-Baselines3)
- NumPy: hỗ trợ xử lý dữ liệu và tính toán số.
- Matplotlib: dùng để trực quan hóa và phân tích kết quả mô phỏng.

- Môi trường phát triển: Visual Studio Code, phục vụ cho việc phát triển, chạy thử nghiệm và quản lý mã nguồn.

2. Dữ liệu và chuẩn hóa

- Dữ liệu nghiên cứu được tạo ra trực tiếp từ mô hình mô phỏng.

- Trạng thái môi trường được biểu diễn dưới dạng số và chuẩn hóa để phù hợp với đầu vào của thuật toán học tăng cường.

- Các tham số được giữ ổn định giữa các thí nghiệm nhằm đảm bảo khả năng so sánh kết quả.

3. Giải pháp triển khai

- Thiết kế mô hình mô phỏng tác tử trên nền tảng Mesa với các thành phần và quy trình hoạt động rõ ràng.

- Kết nối mô hình với môi trường học tăng cường thông qua giao diện Gym.

- Huấn luyện tác tử học tăng cường bằng thuật toán DQN để học chính sách điều khiển.

- Phân tích và so sánh kết quả giữa các kịch bản thông qua các chỉ số định lượng và đánh giá trực quan.

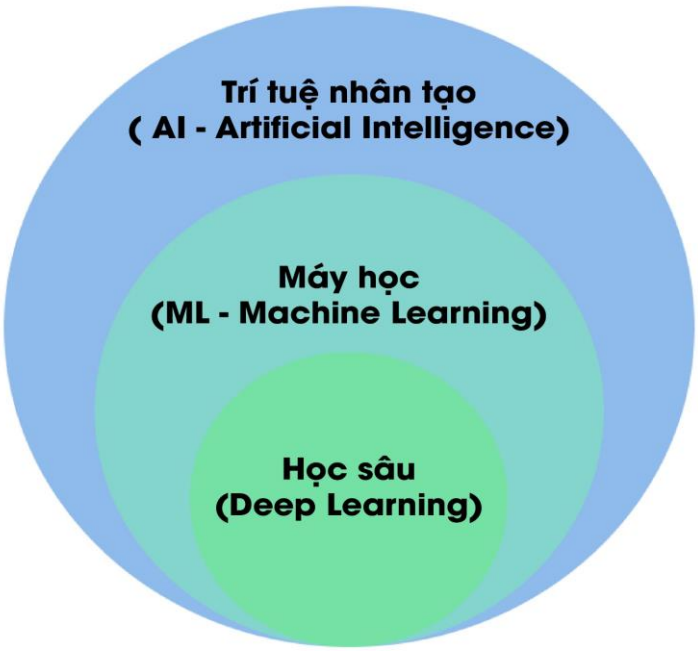
4. Hạ tầng tính toán:

- Mô hình được triển khai trên máy tính cá nhân với tài nguyên CPU.

CHƯƠNG 2 CƠ SỞ LÝ THUYẾT

2.1 Học máy

2.1.1 Tổng quan



Hình 2.1 Mô hình quan hệ giữa Artificial Intelligence (AI), Machine Learning (ML) và Deep Learning (DL)

Học máy (Machine Learning) là một lĩnh vực then chốt của trí tuệ nhân tạo (Artificial Intelligence – AI), tập trung vào việc nghiên cứu và phát triển các phương pháp cho phép hệ thống máy tính tự động học hỏi từ dữ liệu nhằm giải quyết các bài toán cụ thể mà không cần phải lập trình chi tiết từng quy tắc.

Trong học máy, các mô hình được xây dựng để khai thác và phát hiện những mối quan hệ hoặc quy luật tiềm ẩn trong dữ liệu, từ đó hỗ trợ quá trình dự đoán hoặc ra quyết định. Nhờ khả năng học hỏi và thích nghi, các hệ thống học máy có thể hoạt động hiệu quả trong những môi trường phức tạp và thay đổi liên tục, đặc biệt đối với các bài toán mà việc mô tả đầy đủ bằng các quy tắc thủ công là không khả thi. Hiện nay, học máy được ứng dụng rộng rãi trong nhiều lĩnh vực như phân tích dữ liệu, tối ưu hóa hệ thống, mô phỏng hành vi và hỗ trợ ra quyết định tự động.

2.1.2 Phân loại kỹ thuật học máy

Dựa trên cách thức khai thác dữ liệu và cơ chế học, các phương pháp học máy thường được chia thành ba nhóm chính như sau:

- Học có giám sát (Supervised Learning): Học có giám sát là phương pháp trong đó mô hình được huấn luyện trên tập dữ liệu đã được gán nhãn. Mỗi mẫu dữ liệu đầu vào tương ứng với một giá trị đầu ra xác định, giúp mô hình học được mối quan hệ giữa dữ liệu đầu vào và kết quả mong muốn. Sau quá trình huấn luyện, mô hình có khả năng dự đoán hoặc phân loại chính xác các dữ liệu mới chưa từng xuất hiện. Phương pháp này thường được áp dụng cho các bài toán dự đoán và phân loại khi dữ liệu huấn luyện đã có nhãn đầy đủ.

- Học không giám sát (Unsupervised Learning): Học không giám sát sử dụng các tập dữ liệu không được gán nhãn nhằm khám phá cấu trúc, mẫu hình hoặc các đặc trưng tiềm ẩn trong dữ liệu. Mục tiêu chính của phương pháp này là phân nhóm dữ liệu hoặc rút trích thông tin quan trọng mà không cần biết trước kết quả đầu ra. Do thiếu nhãn tham chiếu, việc đánh giá hiệu quả của các mô hình học không giám sát thường phức tạp hơn so với học có giám sát.

- Học tăng cường (Reinforcement Learning): Học tăng cường là phương pháp trong đó một tác tử (agent) học cách lựa chọn hành động thông qua quá trình tương tác liên tục với môi trường. Thay vì được cung cấp sẵn các hành động đúng hoặc sai, tác tử chỉ nhận được phản hồi dưới dạng phần thưởng hoặc hình phạt sau mỗi hành động. Mục tiêu của học tăng cường là tối đa hóa tổng phần thưởng tích lũy theo thời gian, do đó phương pháp này đặc biệt phù hợp với các bài toán ra quyết định tuần tự và mô phỏng các hệ thống động.

2.2 Học tăng cường

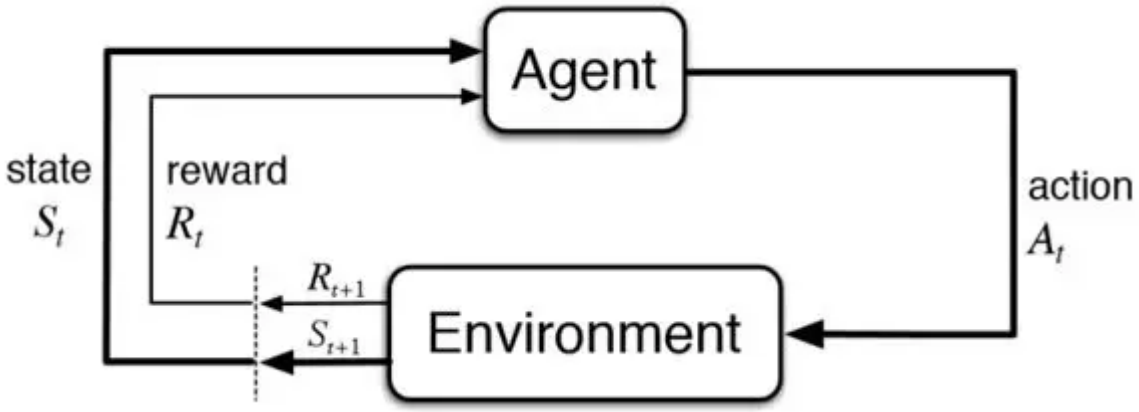
2.2.1 Tổng quan

Học tăng cường (Reinforcement Learning – RL) là một nhánh quan trọng của học máy, tập trung vào việc nghiên cứu cách một tác tử học chính sách hành động tối ưu thông qua tương tác với môi trường. Trong quá trình này, tác tử quan sát trạng thái của môi

trường, lựa chọn hành động, và nhận về một giá trị phần thưởng phản ánh mức độ phù hợp của hành động đó.

Một bài toán học tăng cường thường bao gồm các thành phần cơ bản:

- Tác tử (Agent): thực thể đưa ra quyết định.
- Môi trường (Environment): không gian mà tác tử tương tác.
- Trạng thái (State): biểu diễn tình trạng hiện tại của môi trường.
- Hành động (Action): lựa chọn của tác tử tại mỗi trạng thái.
- Phần thưởng (Reward): tín hiệu phản hồi từ môi trường.



Hình 2.2 Mô hình học tăng cường

Một bài toán học tăng cường điển hình thường được mô tả thông qua mô thức tương tác giữa tác tử và môi trường, như minh họa ở Hình 2.1. Trong bài toán này, một tác tử (Agent) liên tục tương tác với một môi trường (Environment). Cụ thể, tại mỗi thời điểm t, tác tử lựa chọn một hành động A_t và thực hiện hành động đó lên môi trường. Sau khi nhận hành động từ tác tử, môi trường sẽ chuyển sang một trạng thái mới và thông qua cơ chế quan sát (Perceive), tác tử có thể nhận biết được sự chuyển dịch trạng thái của môi trường từ S_t sang S_{t+1}, đồng thời nhận được một giá trị phần thưởng R_{t+1}.

Phần thưởng có thể được xem như một thước đo đánh giá mức độ tốt hay xấu của hành động mà tác tử vừa thực hiện, cũng như mức độ ảnh hưởng của hành động đó đối với

mục tiêu của bài toán. Trên cơ sở này, bài toán học tăng cường được phát biểu một cách tổng quát là: làm thế nào để điều khiển tác tử sao cho tổng phần thưởng mà nó thu được là lớn nhất. Mục tiêu cuối cùng của tác tử là học được một chính sách ánh xạ từ trạng thái sang hành động, nhằm tối đa hóa tổng phần thưởng kỳ vọng trong dài hạn.

2.2.2 Lợi ích của học tăng cường

- Thay vì được lập trình sẵn các quy tắc cố định, tác tử học tăng cường có khả năng tự điều chỉnh hành vi dựa trên kết quả đạt được trong quá trình học.
- Khả năng ra quyết định linh hoạt theo thời gian. Trong các bài toán có tính động và nhiều yếu tố không chắc chắn, RL cho phép hệ thống thích nghi với sự thay đổi của môi trường và lựa chọn hành động phù hợp tại từng thời điểm cụ thể.
- Không yêu cầu mô tả chính xác toàn bộ mô hình toán học của hệ thống. Phương pháp này có thể học trực tiếp từ trải nghiệm và phản hồi của môi trường, do đó phù hợp với các bài toán phức tạp hoặc khó mô hình hóa bằng các phương pháp truyền thống.
- Cho phép tối ưu mục tiêu dài hạn thông qua việc thiết kế hàm phần thưởng phù hợp. Điều này giúp hệ thống không chỉ quan tâm đến kết quả tức thời mà còn cân nhắc tác động của các quyết định trong suốt quá trình hoạt động.

Nhờ những đặc điểm trên, học tăng cường được xem là một hướng tiếp cận hiệu quả và linh hoạt trong việc giải quyết các bài toán ra quyết định phức tạp, đặc biệt khi kết hợp với các mô hình mô phỏng.

2.2.3 Các bài toán áp dụng học tăng cường

Trong thực tế, học tăng cường đã được ứng dụng thành công trong nhiều lĩnh vực khác nhau. Trong lĩnh vực điều khiển và tối ưu, RL được sử dụng để điều khiển robot, quản lý giao thông, tối ưu hóa hệ thống năng lượng và các bài toán điều phối tài nguyên. Các bài toán này đều yêu cầu hệ thống thích nghi liên tục với trạng thái thay đổi của môi trường.

Trong lĩnh vực kinh tế và quản lý, học tăng cường được áp dụng cho các bài toán ra quyết định chiến lược như tối ưu hóa chuỗi cung ứng, định giá động, quản lý danh mục đầu tư và cân bằng giữa lợi ích và chi phí trong dài hạn. Đặc trưng của các bài toán này là tồn tại sự đánh đổi giữa nhiều mục tiêu khác nhau.

Đặc biệt, trong lĩnh vực y tế và dịch tễ học, học tăng cường ngày càng được quan tâm trong các bài toán hỗ trợ ra quyết định chính sách. RL có thể được sử dụng để lựa chọn thời điểm và mức độ áp dụng các biện pháp can thiệp như giãn cách xã hội, hạn chế tiếp xúc hoặc tiêm chủng, nhằm giảm thiểu tác động của dịch bệnh trong khi vẫn cân nhắc chi phí xã hội.

Các bài toán kiểm soát dịch bệnh có nhiều điểm tương đồng với bài toán học tăng cường: diễn biến dịch thay đổi theo thời gian, các quyết định can thiệp ảnh hưởng lâu dài đến hệ thống, và môi trường thường khó mô hình hóa chính xác bằng các phương pháp truyền thống. Do đó, việc áp dụng học tăng cường trong nghiên cứu này nhằm khám phá khả năng học và thích nghi của tác tử trong môi trường mô phỏng dịch bệnh, từ đó hỗ trợ việc đánh giá hiệu quả của các chính sách can thiệp khác nhau.

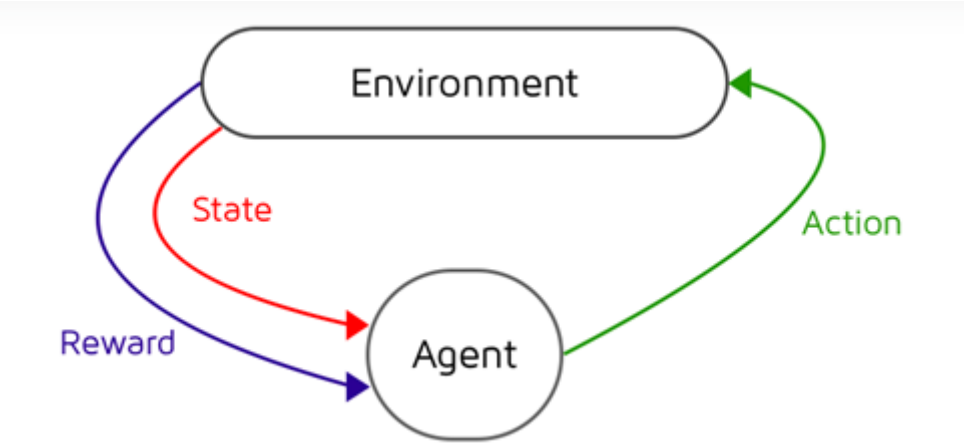
2.2.4 Mô hình Markov Decision Process (MDP)

Quy trình quyết định Markov (Markov Decision Process – MDP) là một khung lý thuyết cơ bản trong học tăng cường, được sử dụng để mô hình hóa các bài toán ra quyết định theo thời gian. Trong thực tế, hầu hết các bài toán học tăng cường đều có thể được biểu diễn dưới dạng MDP.

Một MDP được xác định bởi năm thành phần chính:

- Tập trạng thái S (State), mô tả các trạng thái có thể xảy ra của môi trường
- Tập hành động A (Action), đại diện cho các hành động mà tác tử có thể thực hiện
- Hàm xác suất chuyển trạng thái P, xác định xác suất chuyển từ trạng thái hiện tại sang trạng thái tiếp theo khi thực hiện một hành động
- Hàm phần thưởng R (Reward), phản ánh mức độ tốt hay xấu của một hành động thông qua giá trị phần thưởng nhận được

- Hệ số chiết khấu γ, dùng để điều chỉnh mức độ quan trọng giữa phần thưởng hiện tại và phần thưởng trong tương lai



Hình 2.3 Mô hình tương tác giữa tác tử và môi trường trong bài toán học tăng cường (MDP)

Tại mỗi thời điểm, môi trường cung cấp cho tác tử trạng thái (State) hiện tại, dựa trên đó tác tử lựa chọn một hành động (Action) để thực hiện. Sau khi hành động được áp dụng, môi trường chuyển sang trạng thái mới và phản hồi cho tác tử một phần thưởng (Reward) tương ứng, tạo thành một vòng lặp tương tác liên tục.

Mục tiêu của bài toán MDP là tìm ra chiến lược hành động tối ưu (policy) nhằm tối đa hóa tổng phần thưởng tích lũy theo thời gian. MDP dựa trên giả định Markov, theo đó trạng thái tiếp theo của hệ thống chỉ phụ thuộc vào trạng thái hiện tại và hành động được thực hiện, mà không phụ thuộc vào toàn bộ lịch sử trước đó. Giả định này giúp đơn giản hóa quá trình mô hình hóa bài toán và đóng vai trò nền tảng cho các thuật toán học tăng cường, bao gồm Q-learning và các phương pháp học tăng cường dựa trên mạng nơ-ron sâu.

2.2.5 Một số thuật toán học tăng cường

2.2.5.1 Q-learning

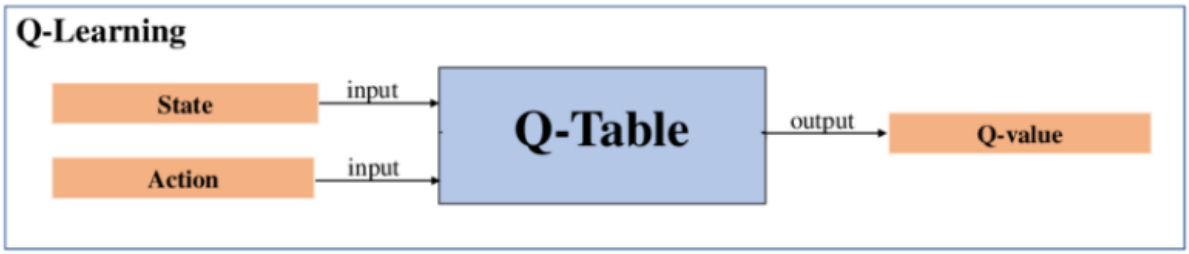
Q-learning là một thuật toán học tăng cường phổ biến thuộc nhóm học không mô hình (model-free) và off-policy, đóng vai trò nền tảng cho nhiều thuật toán học tăng cường hiện đại. Thuật toán này nhằm mục tiêu học hàm giá trị hành động $Q(s, a)$, biểu diễn

giá trị kỳ vọng của tổng phần thưởng khi tác tử thực hiện hành động a tại trạng thái s và sau đó tuân theo chính sách tối ưu.

Quy tắc cập nhật của Q-learning được xác định như sau:

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[r + \gamma \max_{a'} Q(s',a') - Q(s,a) \right] \qquad (2\text{-}1)$$

Trong đó a là tốc độ học, γ là hệ số chiết khấu và r là phần thưởng nhận được sau khi thực hiện hành động.

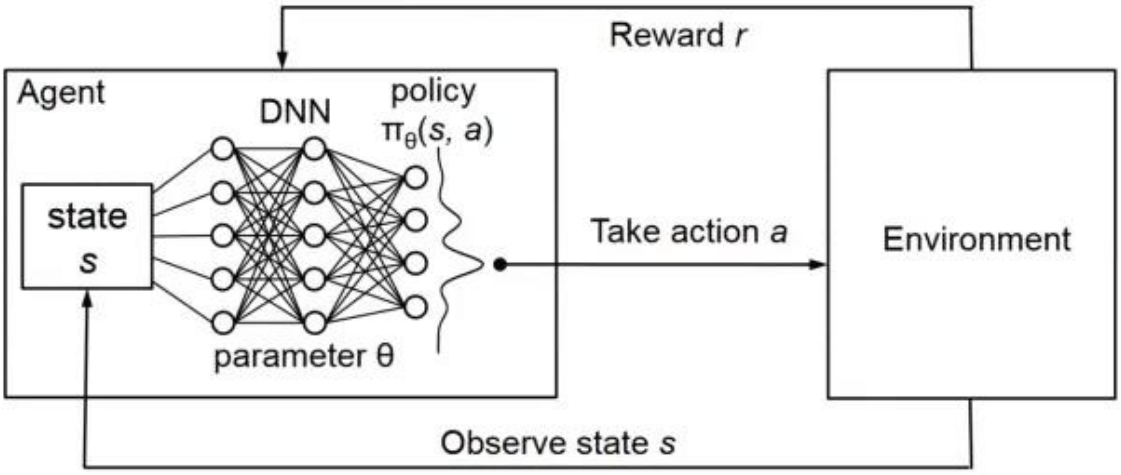


Hình 2.4 Kiến trúc hoạt động cơ bản của thuật toán Q-learning

Mặc dù Q-learning đơn giản và dễ triển khai, thuật toán này gặp hạn chế lớn khi áp dụng cho các bài toán có không gian trạng thái lớn, do việc lưu trữ bảng Q-table trở nên không khả thi. Hạn chế này là động lực chính dẫn đến sự ra đời của các phương pháp học tăng cường dựa trên mạng nơ-ron sâu, tiêu biểu là DQN.

2.2.5.2 Deep Q-Network (DQN)

Deep Q-Network (DQN) là một mở rộng quan trọng của Q-learning, trong đó mạng nơ-ron sâu được sử dụng để xấp xỉ hàm giá trị hành động $Q(s,a)$ thay vì lưu trữ dưới dạng bảng. Nhờ đó, DQN có khả năng xử lý hiệu quả các bài toán có không gian trạng thái lớn hoặc liên tục, vốn không thể giải quyết bằng Q-learning truyền thống.



Hình 2.5 Kiến trúc thuật toán DQN

Trong thuật toán Deep Q-Network (DQN), mạng nơ ron nhận trạng thái s làm đầu vào và cho ra tập các giá trị Q tương ứng với tất cả các hành động khả thi trong không gian hành động. Dựa trên các giá trị này, tác tử có thể lựa chọn hành động tối ưu tại mỗi thời điểm.

Quá trình huấn luyện mạng trong DQN nhằm tối thiểu hóa sai số giữa giá trị Q dự đoán bởi mạng và giá trị Q mục tiêu, được xác định theo công thức:

$$y = r + \gamma \max_{a'} Q_{\text{target}}(s', a') \qquad (2\text{-}2)$$

Trong đó, r là phần thưởng nhận được sau khi thực hiện hành động, γ là hệ số chiết khấu, và Q_{target} là giá trị Q được ước lượng bởi mạng nơ-ron mục tiêu.

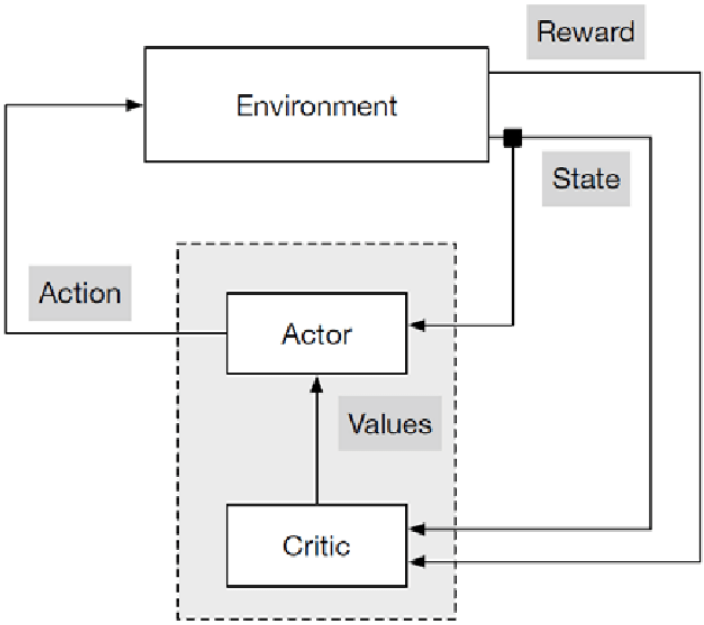
Để đảm bảo quá trình huấn luyện ổn định và hội tụ, DQN áp dụng hai kỹ thuật quan trọng:

- Replay Memory: lưu trữ các trải nghiệm (s, a, r, s′) và huấn luyện mạng bằng cách lấy mẫu ngẫu nhiên từ bộ nhớ, giúp phá vỡ sự phụ thuộc theo chuỗi thời gian của dữ liệu.

- Target Network: sử dụng một mạng nơ-ron mục tiêu riêng biệt để tính toán giá trị Q đích, từ đó giảm dao động và tránh hiện tượng mất ổn định trong quá trình cập nhật trọng số.

Nhờ các cải tiến trên, DQN đã chứng minh hiệu quả vượt trội trong nhiều bài toán điều khiển và ra quyết định phức tạp, và là thuật toán chính được sử dụng trong đồ án này.

2.2.5.3 Actor–Critic



Hình 2.6 Kiến trúc thuật toán Actor-Critic

Actor–Critic là nhóm thuật toán học tăng cường kết hợp giữa hai hướng tiếp cận: dựa trên chính sách và dựa trên hàm giá trị. Thuật toán bao gồm hai thành phần chính: Actor, chịu trách nhiệm học chính sách và lựa chọn hành động, và Critic, đảm nhiệm việc đánh giá chất lượng của hành động thông qua hàm giá trị.

Cách tiếp cận Actor–Critic giúp giảm phương sai trong quá trình huấn luyện và cải thiện tốc độ hội tụ so với các phương pháp Policy Gradient thuần túy. Tuy nhiên, do độ phức tạp cao, các thuật toán Actor–Critic chủ yếu được đề cập như một hướng phát triển mở rộng và không được triển khai trực tiếp trong phạm vi đồ án này.

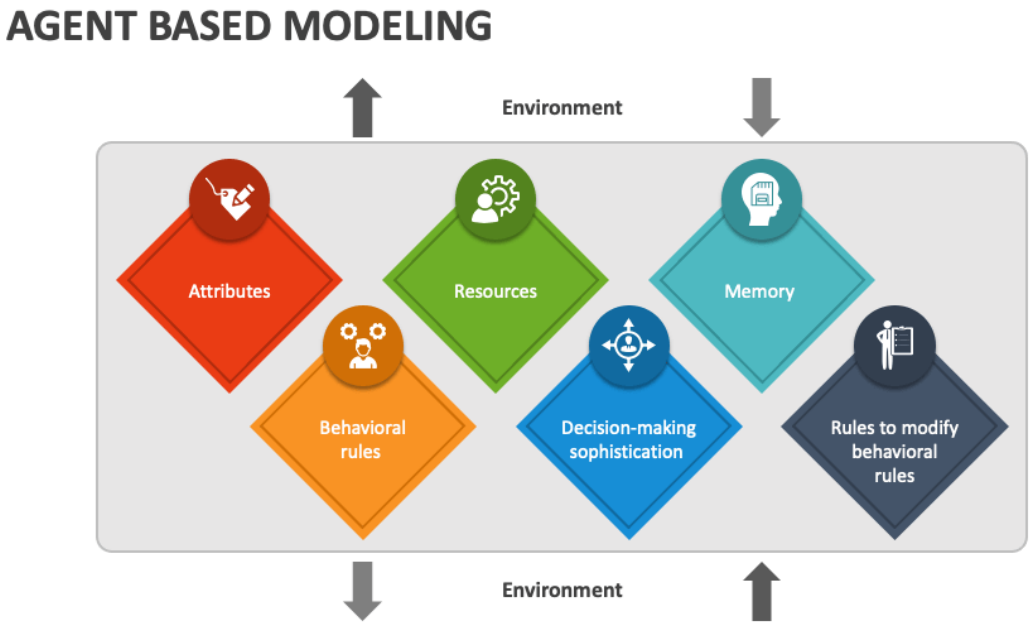
2.3 Mô phỏng dựa trên tác tử (Agent-Based Modeling)

2.3.1 Khái niệm

Mô phỏng dựa trên tác tử (Agent-Based Modeling – ABM) là một phương pháp mô hình hóa trong đó hệ thống được biểu diễn bởi tập hợp nhiều tác tử độc lập. Mỗi tác tử có các đặc trưng riêng, tuân theo những quy tắc hành vi nhất định và có khả năng tương tác với các tác tử khác cũng như với môi trường xung quanh.

Khác với các mô hình toán học truyền thống thường mô tả hệ thống ở mức tổng thể, ABM tập trung mô phỏng hành vi ở mức vi mô. Từ sự tương tác cục bộ giữa các tác tử, các hiện tượng vĩ mô và hành vi tổng thể của hệ thống sẽ dần hình thành một cách tự nhiên. Cách tiếp cận này đặc biệt phù hợp với các hệ thống phức tạp, nơi hành vi toàn cục khó suy ra trực tiếp từ các quy luật đơn giản.

2.3.2 Thành phần cơ bản



Hình 2.7 Các thành phần chính trong mô hình mô phỏng dựa trên tác tử (Agent-Based Modeling)

Một mô hình mô phỏng dựa trên tác tử (Agent-Based Modeling – ABM) được xây dựng dựa trên sự tương tác giữa các tác tử và môi trường, trong đó mỗi tác tử được mô tả

thông qua nhiều thành phần chức năng khác nhau, như minh họa trong Hình X.X. Cụ thể, các thành phần chính của mô hình ABM bao gồm:

- Tác tử (Agent): là các thực thể độc lập tồn tại trong môi trường, mỗi tác tử có tập thuộc tính (Attributes) riêng như trạng thái, đặc điểm cá nhân và các biến nội tại phục vụ cho quá trình mô phỏng.
- Quy tắc hành vi (Behavioral rules): xác định cách tác tử phản ứng trước các tác động từ môi trường hoặc từ các tác tử khác, từ đó quyết định hành động được thực hiện tại mỗi bước thời gian.
- Tài nguyên (Resources): đại diện cho các yếu tố mà tác tử có thể sử dụng, khai thác hoặc chịu ảnh hưởng trong môi trường, chẳng hạn như không gian tiếp xúc, cơ hội tương tác hoặc các nguồn lực liên quan đến quá trình mô phỏng.
- Bộ nhớ (Memory): cho phép tác tử lưu trữ thông tin về các trạng thái hoặc hành động trong quá khứ, từ đó ảnh hưởng đến hành vi trong tương lai.
- Cơ chế ra quyết định (Decision-making sophistication): phản ánh mức độ phức tạp trong quá trình lựa chọn hành động của tác tử, có thể từ các quy tắc đơn giản đến các cơ chế ra quyết định nâng cao.
- Cơ chế điều chỉnh hành vi (Rules to modify behavioral rules): cho phép tác tử thay đổi hoặc thích nghi các quy tắc hành vi của mình theo thời gian, dựa trên trải nghiệm hoặc phản hồi từ môi trường.
- Môi trường (Environment): là không gian bao quanh nơi các tác tử tồn tại và tương tác, đóng vai trò cung cấp thông tin đầu vào và tiếp nhận các hành động do tác tử thực hiện.

Thông qua việc lặp lại quá trình tương tác và cập nhật trạng thái theo từng bước thời gian, mô hình ABM cho phép quan sát sự hình thành các hành vi tập thể và sự tiến hóa của toàn bộ hệ thống từ các quy tắc cục bộ ở mức tác tử.

2.3.3 Ứng dụng

ABM được ứng dụng rộng rãi trong nhiều lĩnh vực như khoa học xã hội, kinh tế, sinh học, giao thông và dịch tễ học. Trong lĩnh vực mô phỏng dịch bệnh, mô hình dựa trên tác tử cho phép biểu diễn chi tiết trạng thái của từng cá nhân (như khỏe mạnh, nhiễm bệnh, hồi phục, tiêm vaccine) và mô phỏng quá trình lây lan thông qua tiếp xúc.

Ưu điểm nổi bật của ABM là khả năng mở rộng, linh hoạt và dễ tích hợp với các phương pháp học máy, đặc biệt là học tăng cường, nhằm xây dựng các tác tử có khả năng thích nghi với môi trường động.

Trong đồ án này, học tăng cường được áp dụng trong bối cảnh mô phỏng đa tác tử, nơi nhiều tác tử cùng tồn tại và tương tác trong một môi trường chung. Việc kết hợp học tăng cường với mô hình mô phỏng giúp đánh giá hiệu quả của các chính sách điều khiển trong những hệ thống phức tạp, khó quan sát trực tiếp ngoài thực tế.

2.4 Nền tảng Mesa

2.4.1 Giới thiệu về Mesa

Mesa là một framework mã nguồn mở viết bằng Python, được thiết kế để hỗ trợ xây dựng và phân tích các mô hình mô phỏng dựa trên tác tử. Mesa cung cấp đầy đủ các thành phần cần thiết để phát triển một mô hình ABM, từ định nghĩa tác tử, môi trường, bộ lập lịch cho đến công cụ thu thập và trực quan hóa dữ liệu.

Với việc sử dụng Python, Mesa cho phép dễ dàng tích hợp với các thư viện khoa học dữ liệu và học máy, tạo điều kiện thuận lợi cho việc mở rộng mô hình và thử nghiệm các thuật toán điều khiển thông minh.

2.4.2 Kiến trúc cơ bản của Mesa

Một mô hình Mesa thường được xây dựng dựa trên các thành phần chính sau:

- Agent: lớp đại diện cho tác tử, kế thừa từ mesa.Agent, chứa trạng thái và hành vi của tác tử.
- Model: lớp quản lý toàn bộ mô hình, kế thừa từ mesa.Model, chịu trách nhiệm khởi tạo môi trường, tác tử và điều phối quá trình mô phỏng.

- Scheduler: điều khiển thứ tự thực thi các tác tử trong mỗi bước thời gian.
- Space/Grid: biểu diễn không gian mô phỏng, thường được sử dụng để xác định vị trí và tương tác giữa các tác tử.
- Data Collector: thu thập và lưu trữ dữ liệu trong quá trình mô phỏng để phục vụ phân tích.

Cấu trúc này giúp mô hình được tổ chức rõ ràng, dễ bảo trì và dễ mở rộng.

2.4.3 Ưu điểm của Mesa trong nghiên cứu mô phỏng

Mesa có nhiều ưu điểm nổi bật trong nghiên cứu và giảng dạy:

- Dễ tiếp cận và sử dụng nhờ cú pháp Python đơn giản.
- Hỗ trợ trực quan hóa và thu thập dữ liệu trong quá trình mô phỏng.
- Cho phép mở rộng mô hình linh hoạt và tích hợp với các thuật toán học máy. Phù hợp cho việc thử nghiệm và đánh giá nhiều kịch bản khác nhau trong cùng một mô hình.

Nhờ những ưu điểm này, Mesa được lựa chọn làm nền tảng mô phỏng chính trong đồ án.

2.5 Mô hình Virus on Network

2.5.1 Tổng quan mô hình Virus on Network

Virus on Network là một trong những mô hình ví dụ cơ bản nhưng có ý nghĩa quan trọng được cung cấp trong thư viện Mesa, nhằm minh họa cách tiếp cận mô phỏng dịch bệnh dựa trên tác tử kết hợp với mạng lưới tiếp xúc. Khác với các mô hình dịch tễ truyền thống dựa trên phương trình vi phân, Virus on Network mô hình hóa từng cá thể trong quần thể như một tác tử (agent) độc lập, đồng thời sử dụng mạng lưới (network) để biểu diễn cấu trúc tiếp xúc xã hội giữa các cá thể.

Trong mô hình này, mỗi tác tử được gán vào một node trên mạng lưới, và các cạnh (edges) biểu diễn khả năng tiếp xúc trực tiếp giữa hai cá thể. Quá trình lây lan virus

không diễn ra một cách đồng đều trên toàn bộ quần thể mà phụ thuộc trực tiếp vào cấu trúc mạng lưới, phản ánh thực tế rằng con người chỉ tiếp xúc với một tập con các cá nhân khác trong xã hội. Cách tiếp cận này cho phép mô hình tái hiện các hiện tượng phát sinh như bùng phát cục bộ, siêu lây nhiễm hoặc sự khác biệt trong tốc độ lây lan giữa các nhóm cá thể.

Virus on Network thường được sử dụng như một mô hình nền tảng để nghiên cứu ảnh hưởng của cấu trúc mạng lưới lên sự lan truyền dịch bệnh, đồng thời là điểm khởi đầu thuận lợi để mở rộng sang các mô hình phức tạp hơn.

2.5.2 Mô hình SIR cổ điển



Hình 2.8 Mô hình SIR

Kermack và Mc Kendrick là những người tiên phong đưa ra các phương trình vi phân dành cho mô hình SIR vào năm 1927, mô hình này là viết tắt của (Susceptible – có khả năng bị nhiễm); (Infected – Nhiễm bệnh); (Recovered – Phục hồi).

Trong mô hình SIR cổ điển, sự chuyển đổi giữa các trạng thái được mô tả thông qua hệ phương trình vi phân liên tục:

- S → I: xảy ra khi cá thể nhạy cảm tiếp xúc với cá thể nhiễm bệnh, với xác suất phụ thuộc vào hệ số lây nhiễm
- I → R: xảy ra sau một khoảng thời gian nhiễm nhất định, đại diện cho quá trình hồi phục hoặc bị loại khỏi quần thể

Mô hình SIR truyền thống có ưu điểm là đơn giản, dễ phân tích và phù hợp để nghiên cứu xu hướng lây lan ở mức độ vĩ mô. Tuy nhiên, mô hình này giả định rằng:

- Mọi cá thể trong quần thể có xác suất tiếp xúc như nhau
- Không xét đến cấu trúc mạng lưới tiếp xúc
- Không phản ánh được sự khác biệt hành vi giữa các cá thể

Do đó, khi áp dụng vào các bài toán mô phỏng chi tiết, đặc biệt là trong môi trường có cấu trúc mạng xã hội phức tạp, mô hình SIR cổ điển tỏ ra chưa đủ linh hoạt.

2.5.3 Mô hình Virus on Network trong Mesa

Để khắc phục các hạn chế của mô hình SIR cổ điển, Mesa – một nền tảng mô phỏng dựa trên tác tử bằng Python – đã giới thiệu ví dụ Virus on Network, trong đó quá trình lây lan dịch bệnh được mô phỏng trên một mạng lưới tiếp xúc.

- Trong mô hình Virus on Network:

- Mỗi cá thể được mô hình hóa như một tác tử (agent)
- Các mối quan hệ tiếp xúc giữa cá thể được biểu diễn bằng mạng lưới (network), thường được xây dựng bằng thư viện NetworkX
- Lây nhiễm chỉ xảy ra giữa các cá thể có kết nối trực tiếp trong mạng

- Mỗi tác tử trong mô hình Mesa có các thuộc tính cơ bản như:

- Trạng thái sức khỏe (S, I hoặc R)
- Thời gian đã bị nhiễm
- Xác suất lây nhiễm và xác suất hồi phục

- Quá trình mô phỏng được thực hiện theo các bước thời gian rời rạc (time step). Tại mỗi bước:

- Tác tử nhiễm bệnh có thể lây cho các tác tử lân cận trong mạng
- Trạng thái của tác tử được cập nhật dựa trên xác suất và thời gian nhiễm

- Cách tiếp cận này cho phép mô hình phản ánh rõ ràng:

- Tác động của cấu trúc mạng lưới tới quá trình lây lan
- Sự khác biệt hành vi giữa các cá thể
- Tính ngẫu nhiên và không đồng nhất của dịch bệnh

Việc triển khai mô hình SIR trên mạng lưới giúp phản ánh rõ ràng hơn vai trò của cấu trúc xã hội trong quá trình lây lan, thay vì giả định tiếp xúc ngẫu nhiên và đồng đều như trong các mô hình SIR cổ điển. Tuy nhiên, mô hình Virus on Network gốc của Mesa vẫn chỉ dừng lại ở mô hình SIR, chưa xét đến các yếu tố can thiệp quan trọng trong bối cảnh dịch bệnh hiện đại như tiêm vaccine hoặc chính sách kiểm soát dịch theo thời gian.

2.5.4 Mô hình SIRV

Trong thực tế, đặc biệt là đối với các dịch bệnh như COVID-19, vaccine đóng vai trò quan trọng trong việc giảm tốc độ lây lan và mức độ nghiêm trọng của dịch. Do đó, để mô hình hóa sát hơn bối cảnh thực tế, đồ án mở rộng mô hình SIR gốc của Mesa thành mô hình SIRV, bằng cách bổ sung trạng thái:

V (Vaccinated) – Nhóm cá thể đã được tiêm vaccine

Trong mô hình SIRV, các trạng thái và chuyển đổi được mở rộng như sau:

- S → I: cá thể chưa tiêm vaccine bị nhiễm bệnh
- I → R: cá thể nhiễm bệnh hồi phục
- S → V: cá thể được tiêm vaccine
- V → I: cá thể đã tiêm vaccine vẫn có khả năng bị nhiễm, nhưng với xác suất thấp hơn

Khác với các giả định lý tưởng, mô hình SIRV trong đồ án không xem vaccine là tuyệt đối. Thay vào đó, vaccine được mô hình hóa như một yếu tố:

- Giảm xác suất nhiễm bệnh
- Làm chậm quá trình lây lan trong mạng lưới

- Tạo ra sự khác biệt rõ rệt giữa các nhóm cá thể
- Việc mở rộng từ SIR sang SIRV cho phép mô hình:
- Phản ánh sát hơn động lực dịch bệnh trong thế giới thực
- Tạo thêm không gian hành động cho các chính sách can thiệp
- Tăng tính thực tiễn khi kết hợp với học tăng cường để tối ưu hóa chiến lược kiểm soát dịch

2.5.5 So sánh SIR và SIRV

Để làm rõ sự khác biệt giữa mô hình gốc và mô hình mở rộng, Bảng dưới đây trình bày so sánh giữa SIR và SIRV:

Bảng 2.1 Bảng so sánh mô hình SIR và SIRV

Tiêu chí	**Mô hình SIR**	**Mô hình SIRV**
Số trạng thái	3 (S, I, R)	4 (S, I, R, V)
Xét yếu tố vaccine	Không	Có
Khả năng phản ánh thực tế	Hạn chế	Cao hơn
Phù hợp mô phỏng COVID-19	Thấp	Cao
Không gian chính sách can thiệp	Hạn chế	Mở rộng
Khả năng tích hợp RL	Có	Tốt hơn

Từ bảng so sánh có thể thấy rằng, mô hình SIRV không chỉ kế thừa ưu điểm của mô hình SIR mà còn mở rộng khả năng phân tích và điều khiển hệ thống. Việc bổ sung trạng

thái V giúp mô hình trở nên linh hoạt hơn, tạo điều kiện thuận lợi cho việc áp dụng học tăng cường nhằm học các chính sách can thiệp tối ưu trong bối cảnh dịch bệnh phức tạp.

2.6 Kết hợp học tăng cường với mô phỏng trên Mesa

2.6.1 Động cơ kết hợp học tăng cường và ABM

Trong các mô hình mô phỏng dịch bệnh truyền thống được xây dựng trên nền tảng Mesa, hành vi của tác tử thường được xác định thông qua các quy tắc cố định hoặc các kịch bản được thiết kế sẵn. Ví dụ, xác suất lây nhiễm, tốc độ hồi phục hay mức độ tương tác xã hội thường không thay đổi hoặc chỉ thay đổi theo các tham số được thiết lập trước. Cách tiếp cận này giúp mô hình dễ xây dựng và dễ kiểm soát, tuy nhiên lại tồn tại hạn chế lớn về khả năng thích nghi khi môi trường mô phỏng thay đổi theo thời gian.

Trong thực tế, các biện pháp can thiệp dịch bệnh như giãn cách xã hội, phong tỏa hay tiêm chủng thường không được áp dụng theo các quy tắc cứng nhắc, mà phải liên tục điều chỉnh dựa trên diễn biến dịch bệnh, nguồn lực sẵn có và chi phí xã hội. Do đó, việc sử dụng các kịch bản cố định trong mô phỏng có thể không phản ánh đầy đủ tính động và tính bất định của các quyết định trong thế giới thực.

Học tăng cường cung cấp một cách tiếp cận phù hợp để khắc phục hạn chế này. Thay vì xác định trước chiến lược hành động, tác tử học tăng cường có khả năng tự động học chính sách tối ưu thông qua quá trình tương tác lặp lại với môi trường. Việc tích hợp học tăng cường vào mô hình dựa trên tác tử cho phép hệ thống không chỉ mô phỏng quá trình lây lan dịch bệnh, mà còn học cách điều chỉnh các biện pháp can thiệp một cách thích nghi theo từng trạng thái của hệ thống.

Phương pháp này đặc biệt phù hợp với bối cảnh nghiên cứu dịch COVID-19, nơi các quyết định can thiệp cần được điều chỉnh linh hoạt theo diễn biến thực tế của dịch bệnh.

2.6.2 Vai trò của tác tử học tăng cường trong mô hình

Trong phạm vi đồ án, tác tử học tăng cường không đại diện cho từng cá thể trong quần thể, mà đóng vai trò là một thực thể ra quyết định ở cấp độ vĩ mô. Tác tử này quan sát trạng thái tổng thể của môi trường mô phỏng, bao gồm các thông tin như số lượng ca

nhiễm, tỷ lệ cá thể đã được tiêm vaccine, hoặc mức độ lây lan theo thời gian, từ đó đưa ra quyết định về mức độ can thiệp phù hợp.

Các hành động do tác tử học tăng cường lựa chọn không tác động trực tiếp đến từng cá thể riêng lẻ, mà ảnh hưởng gián tiếp đến toàn bộ hệ thống thông qua việc điều chỉnh các tham số hoặc cấu trúc của mô hình Mesa, chẳng hạn như giảm mức độ tương tác trên mạng lưới hoặc giới hạn số lượng tiếp xúc giữa các tác tử. Cách tiếp cận này phản ánh sát hơn vai trò của các nhà hoạch định chính sách trong thực tế, nơi các quyết định thường mang tính toàn cục và ảnh hưởng đến cả cộng đồng.

Phần thưởng (reward) được thiết kế nhằm phản ánh mục tiêu tối ưu của bài toán, bao gồm việc giảm số ca nhiễm đồng thời hạn chế chi phí xã hội do các biện pháp can thiệp gây ra. Thông qua tín hiệu phần thưởng, tác tử học tăng cường dần học được mối quan hệ giữa trạng thái dịch bệnh, hành động can thiệp và hậu quả của các quyết định đó, từ đó hình thành chính sách can thiệp phù hợp hơn theo thời gian.

2.6.3 Lợi ích của việc áp dụng học tăng cường trong mô phỏng dịch bệnh

Việc áp dụng học tăng cường trong mô phỏng dịch bệnh mang lại nhiều lợi ích đáng kể so với các phương pháp mô phỏng truyền thống dựa trên quy tắc cố định hoặc các kịch bản được thiết kế sẵn. Sau đây là 5 lợi ích chính khi áp dụng:

- Cho phép mô hình tự động học chính sách can thiệp tối ưu thông qua quá trình tương tác với môi trường, thay vì phụ thuộc hoàn toàn vào kiến thức và giả định ban đầu của người thiết kế.

Điều này đặc biệt quan trọng trong bối cảnh dịch bệnh, nơi các yếu tố như mức độ lây lan, hiệu quả vaccine hay hành vi xã hội có thể thay đổi theo thời gian và khó dự đoán chính xác.

- Có khả năng thích nghi động theo trạng thái của hệ thống.

Khác với các chiến lược can thiệp tĩnh, tác tử học tăng cường có thể điều chỉnh mức độ can thiệp dựa trên diễn biến hiện tại của dịch bệnh, chẳng hạn như tăng cường biện pháp khi số ca nhiễm gia tăng hoặc nới lỏng khi dịch được kiểm soát.Nhờ đó, mô hình phản

ánh sát hơn cách ra quyết định trong thực tế của các nhà quản lý và hoạch định chính sách.

- Cho phép tối ưu đồng thời nhiều mục tiêu xung đột, chẳng hạn như giảm số ca nhiễm trong khi vẫn hạn chế chi phí xã hội và kinh tế do các biện pháp can thiệp gây ra.

Thông qua thiết kế hàm phần thưởng phù hợp, mô hình có thể tìm ra sự cân bằng giữa hiệu quả kiểm soát dịch bệnh và mức độ can thiệp chấp nhận được, điều mà các mô hình mô phỏng truyền thống khó thực hiện một cách hệ thống.

- Giúp khám phá các chiến lược can thiệp mới, không bị giới hạn bởi các kịch bản được xác định trước.

Trong quá trình huấn luyện, tác tử có thể thử nghiệm nhiều chuỗi hành động khác nhau và học được những chính sách hiệu quả mà con người có thể chưa từng nghĩ tới, từ đó mở ra khả năng phát hiện các phương án can thiệp tiềm năng.

- Sự kết hợp giữa học tăng cường và mô hình dựa trên tác tử tạo ra một khung nghiên cứu linh hoạt và có khả năng mở rộng.

Mô hình có thể dễ dàng được điều chỉnh để thử nghiệm các tham số mới, bổ sung các yếu tố như vaccine, biến chủng virus hoặc thay đổi hành vi xã hội, đồng thời vẫn giữ nguyên cơ chế học của tác tử. Điều này giúp hệ thống không chỉ phục vụ cho bài toán cụ thể trong đồ án, mà còn có tiềm năng ứng dụng cho các nghiên cứu sâu hơn trong tương lai.

Tóm lại, việc tích hợp học tăng cường vào mô hình mô phỏng dịch bệnh trên Mesa cho phép mở rộng khả năng phân tích của hệ thống, từ mô phỏng thụ động sang mô phỏng có khả năng học và thích nghi. Đây chính là nền tảng quan trọng để nghiên cứu và đánh giá các chính sách can thiệp dịch bệnh trong bối cảnh động và bất định, phù hợp với mục tiêu nghiên cứu của đồ án.

CHƯƠNG 3 CÀI ĐẶT MÔ HÌNH

3.1 Tổng quan

Trong bài toán mô phỏng sự lây lan dịch bệnh trên mạng lưới, yêu cầu đặt ra là mô hình phải phản ánh được hành vi của từng cá thể, sự tương tác giữa các cá thể, cũng như tác động của các biện pháp can thiệp theo thời gian. Ngoài ra, hệ thống cần cho phép thử nghiệm nhiều kịch bản khác nhau và dễ dàng mở rộng khi thay đổi tham số mô phỏng. Vì vậy đồ án lựa chọn phương pháp mô phỏng dựa trên tác tử (Agent-Based Modeling – ABM) kết hợp với học tăng cường (Reinforcement Learning – RL). Trong đó, ABM cho phép mô hình hóa từng cá thể như một tác tử độc lập với trạng thái và hành vi riêng, còn RL được sử dụng để học và tối ưu chính sách can thiệp dựa trên trạng thái toàn cục của hệ thống.

Nền tảng Mesa xây dựng mô hình mô phỏng hỗ trợ tốt cho ABM, dễ tích hợp với các thư viện khoa học dữ liệu và học máy trong Python. Bài toán dịch bệnh được mô hình hóa theo mô hình SIRV, mở rộng từ mô hình SIR truyền thống nhằm phản ánh vai trò của vaccine trong bối cảnh dịch bệnh thực tế như COVID-19.

3.1.1 Phương pháp mô phỏng dịch bệnh (SIRV trên mạng lưới)

Trong đồ án, mỗi cá thể trong quần thể được mô hình hóa như một agent và được gán một trạng thái sức khỏe tại mỗi thời điểm mô phỏng. Các trạng thái được sử dụng bao gồm S (Susceptible), I (Infected), R (Recovered), V (Vaccinated).

Các agent được đặt trên một mạng lưới (network), trong đó mỗi đỉnh tương ứng với một cá thể và mỗi cạnh biểu diễn mối quan hệ tiếp xúc xã hội. Quá trình lây nhiễm xảy ra khi một agent ở trạng thái I tiếp xúc với agent ở trạng thái S thông qua các cạnh trong mạng lưới, với một xác suất lây nhiễm nhất định.

Việc sử dụng mạng lưới giúp mô hình phản ánh tốt hơn sự lây lan không đồng đều của dịch bệnh, thay vì giả định mọi cá thể tiếp xúc ngẫu nhiên với nhau như trong các mô hình trung bình truyền thống.

3.1.2 Phương pháp học tăng cường cho bài toán điều khiển

Trong nhiều mô hình mô phỏng dịch bệnh, các biện pháp can thiệp thường được thiết kế dưới dạng chính sách cố định, ví dụ như áp dụng lockdown khi số ca nhiễm vượt một ngưỡng xác định. Tuy nhiên, cách tiếp cận này có hạn chế là thiếu tính linh hoạt và không thích ứng tốt với diễn biến phức tạp của hệ thống.

Trong bài toán của đồ án, học tăng cường được sử dụng nhằm khắc phục hạn chế trên. Thay vì xác định trước một chính sách can thiệp cố định, tác tử học tăng cường sẽ tự học cách lựa chọn biện pháp phù hợp thông qua quá trình tương tác với môi trường mô phỏng.

Học tăng cường phù hợp với bài toán này vì các yếu tố cơ bản của RL đều được thỏa mãn:

- Có môi trường: môi trường là mô hình mô phỏng dịch bệnh SIRV trên nền tảng Mesa.
- Có hành động: tác tử RL có thể lựa chọn các mức độ can thiệp khác nhau (từ không can thiệp đến lockdown mạnh).
- Có phần thưởng: phần thưởng được thiết kế dựa trên số ca nhiễm và chi phí xã hội của các biện pháp can thiệp.

Trong mô hình, tác tử học tăng cường không điều khiển trực tiếp hành vi của từng cá thể, mà chỉ tác động ở mức chính sách vĩ mô. Các quyết định của tác tử ảnh hưởng gián tiếp đến toàn bộ hệ thống thông qua việc thay đổi mức độ tiếp xúc giữa các cá thể trong mạng lưới.

Cách tiếp cận này phù hợp với bối cảnh thực tế, nơi các nhà hoạch định chính sách không thể kiểm soát hành vi của từng cá nhân, mà chỉ có thể ban hành các biện pháp can thiệp ở cấp độ cộng đồng.

3.1.3 Yêu cầu chức năng

- Mô phỏng được mô hình SIRV trên mạng lưới: Hệ thống phải cho phép theo dõi trạng thái sức khỏe của từng cá thể và quá trình chuyển đổi giữa các trạng thái S, I, R và V theo thời gian.

- Cho phép thay đổi các tham số dịch bệnh: Các tham số như xác suất lây nhiễm, thời gian nhiễm bệnh, hiệu quả vaccine và độ trễ miễn dịch cần có khả năng điều chỉnh để phục vụ việc thử nghiệm nhiều kịch bản khác nhau.

- Cho phép tác tử học tăng cường quan sát trạng thái hệ thống: Môi trường cần cung cấp cho tác tử RL các thông tin tổng hợp phản ánh tình trạng dịch bệnh tại mỗi bước thời gian.

- Cho phép tác tử RL tác động ngược lại mô phỏng: Hành động do tác tử RL lựa chọn phải có ảnh hưởng trực tiếp đến quá trình mô phỏng, cụ thể là thay đổi mức độ tiếp xúc hoặc cường độ tương tác giữa các cá thể.

3.1.4 Yêu cầu phi chức năng

- Dễ mở rộng và điều chỉnh: Hệ thống cần được thiết kế theo hướng mô-đun, cho phép mở rộng thêm các trạng thái, tham số hoặc thuật toán học tăng cường trong tương lai.

- Thời gian mô phỏng ở mức chấp nhận được: Quá trình mô phỏng và huấn luyện học tăng cường cần có thời gian thực thi phù hợp, không quá dài để thuận tiện cho việc thử nghiệm và đánh giá.

- Kết quả có thể trực quan hóa và phân tích: Hệ thống cần hỗ trợ việc thu thập và trực quan hóa các kết quả mô phỏng như số ca nhiễm theo thời gian, mức độ can thiệp và phần thưởng của tác tử RL, phục vụ cho việc đánh giá và thảo luận kết quả.

3.2 Thiết kế mô hình

3.2.1 Thiết kế mô hình SIRV

Như đã nói ở chương 2, mô hình SIRV được xây dựng như một sự mở rộng của mô hình SIR gốc trong mô hình "Virus on a network" của Mesa. Việc bổ sung trạng thái Vaccinated (V) nhằm phản ánh vai trò của vaccine trong kiểm soát dịch bệnh, đặc biệt trong bối cảnh các dịch bệnh hiện đại như COVID-19.

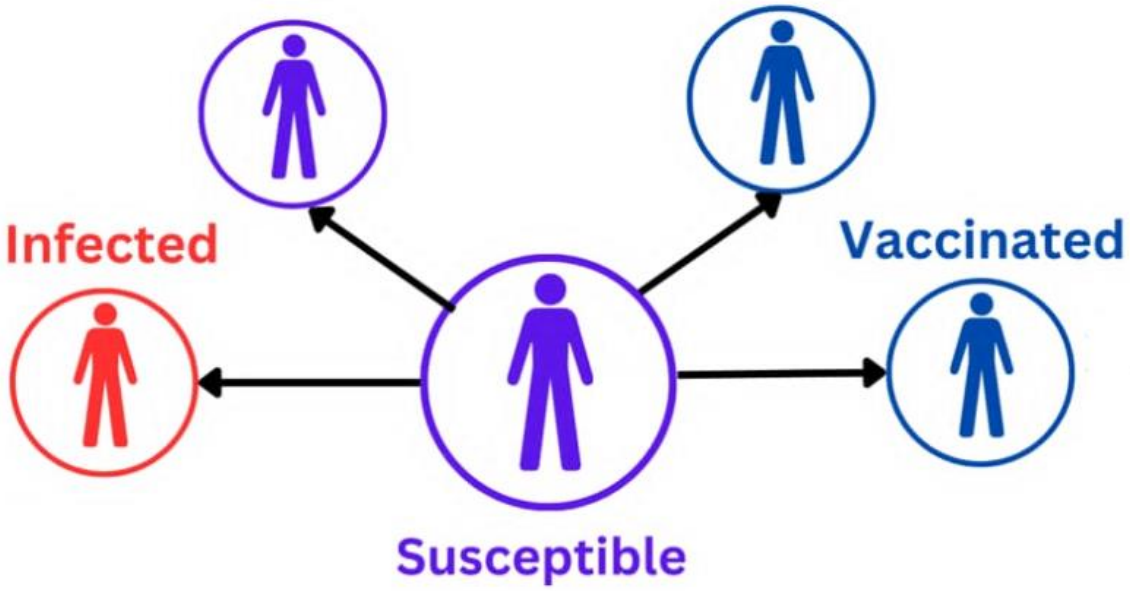
a) Mô tả các trạng thái

- S (Susceptible): Cá thể chưa có miễn dịch và có nguy cơ bị lây nhiễm.
- I (Infected): Cá thể đang mang virus và có khả năng truyền bệnh.
- R (Recovered): Cá thể đã khỏi bệnh và được giả định có miễn dịch.
- V (Vaccinated): Cá thể đã được tiêm vaccine, có khả năng miễn dịch một phần hoặc hoàn toàn.

b) Điều kiện chuyển trạng thái

Các chuyển trạng thái trong mô hình được xác định như sau:

- S → I: Xảy ra khi một cá thể nhạy cảm tiếp xúc với cá thể nhiễm bệnh trong mạng lưới. Xác suất chuyển trạng thái phụ thuộc vào:
    - Xác suất lây nhiễm cơ bản.
    - Số lượng tiếp xúc với cá thể nhiễm.
    - Trạng thái tiêm vaccine.
- I → R: Xảy ra khi cá thể đã nhiễm bệnh đủ thời gian hồi phục định trước.
- S → V: Xảy ra khi chính sách tiêm vaccine được kích hoạt. Việc tiêm vaccine không xảy ra ngẫu nhiên mà chịu sự điều khiển của chính sách can thiệp (do học tăng cường quyết định trong các kịch bản sau).



Hình 3.1 Quá trình lây nhiễm của S (Susceptible) dựa trên xác suất lây truyền

c) Vai trò của vaccine trong mô hình

Vaccine không trực tiếp loại bỏ khả năng lây nhiễm, mà làm giảm xác suất cá thể bị nhiễm khi tiếp xúc với người bệnh. Điều này phản ánh sát hơn thực tế, nơi vaccine giúp giảm nguy cơ nhiễm và mức độ nghiêm trọng của bệnh, thay vì đảm bảo miễn dịch tuyệt đối. Việc mô hình hóa vaccine theo cách này giúp hệ thống linh hoạt hơn và phù hợp để nghiên cứu các chiến lược tiêm chủng khác nhau.

3.2.2 Thiết kế tác tử (Agent)

Trong mô hình mô phỏng dựa trên tác tử, tác tử (agent) là đơn vị cơ bản đại diện cho mỗi cá thể trong quần thể. Mỗi tác tử tồn tại độc lập với trạng thái riêng và tương tác với các tác tử khác thông qua mạng lưới tiếp xúc, trong khi hành vi tiến triển trạng thái của tác tử được xác định bởi các quy tắc mô hình và chính sách can thiệp toàn cục. Việc mô hình hóa ở mức tác tử cho phép hệ thống phản ánh rõ ràng sự khác biệt giữa các cá thể, cũng như các hiện tượng phát sinh từ tương tác cục bộ, điều mà các mô hình trung bình truyền thống khó thể hiện.

Trong đồ án này, mỗi tác tử đại diện cho một cá nhân trong cộng đồng, có khả năng:

- Bị lây nhiễm virus thông qua tiếp xúc,
- Hồi phục sau một khoảng thời gian nhiễm bệnh,
- Được tiêm vaccine và thay đổi mức độ nhạy cảm với virus.

a) Thuộc tính của tác tử

Mỗi tác tử trong mô hình được thiết kế với các thuộc tính chính sau:

- Trạng thái dịch bệnh: Tác tử có thể ở một trong bốn trạng thái:
    - Susceptible (S): Cá thể chưa nhiễm bệnh và có khả năng bị lây.
    - Infected (I): Cá thể đang nhiễm bệnh và có khả năng lây sang người khác.
    - Recovered (R): Cá thể đã hồi phục và được coi là có miễn dịch.
    - Vaccinated (V): Cá thể đã được tiêm vaccine, có khả năng miễn dịch hoặc giảm nguy cơ nhiễm.
- Thời gian nhiễm bệnh: Với các tác tử ở trạng thái Infected, hệ thống lưu trữ số bước thời gian kể từ khi bị nhiễm. Thông tin này được sử dụng để xác định thời điểm chuyển sang trạng thái Recovered.
- Trạng thái tiêm vaccine: Thuộc tính này cho biết tác tử đã được tiêm vaccine hay chưa. Trạng thái này ảnh hưởng trực tiếp đến xác suất lây nhiễm khi tác tử tiếp xúc với người nhiễm bệnh.

b) Hành vi của tác tử theo từng bước thời gian

Trạng thái của các tác tử lân cận trong mạng lưới được hệ thống sử dụng để xác định khả năng lây nhiễm tại mỗi bước mô phỏng.Trong mỗi bước mô phỏng (time step), tác tử thực hiện các hành vi sau:

- Nếu đang ở trạng thái Susceptible, tác tử có thể bị lây nhiễm với một xác suất phụ thuộc vào:
    - Số lượng hàng xóm đang nhiễm bệnh,

    - Xác suất lây nhiễm cơ bản,
    - Trạng thái đã tiêm vaccine hay chưa.

- Nếu đang ở trạng thái Infected, tác tử tăng bộ đếm thời gian nhiễm và có khả năng chuyển sang trạng thái Recovered khi đủ thời gian hồi phục.
- Nếu chính sách can thiệp cho phép, tác tử ở trạng thái Susceptible có thể được chuyển sang trạng thái Vaccinated.

Cách tiếp cận này giúp mô hình phản ánh được quá trình tiến triển dịch bệnh ở mức cá thể, đồng thời tạo điều kiện để các chính sách can thiệp tác động gián tiếp thông qua hành vi của từng tác tử.

3.2.3 Thiết kế mạng lưới tiếp xúc

Mạng lưới tiếp xúc được xây dựng dựa trên các mô hình mạng phổ biến như mạng Barabási–Albert hoặc mạng Small-World. Trong mô hình, mạng lưới tiếp xúc đóng vai trò trung tâm trong quá trình lây lan dịch bệnh. Mức độ tiếp xúc giữa các tác tử có thể thay đổi theo thời gian, phụ thuộc vào chính sách can thiệp do tác tử học tăng cường quyết định

a) Mô hình hóa mạng lưới tiếp xúc

Trong mô hình, mạng lưới tiếp xúc xã hội được biểu diễn bằng một đồ thị (graph), trong đó:

- Mỗi node đại diện cho một địa điểm hoặc cụm tiếp xúc (ví dụ: lớp học, khu dân cư,…).
- Mỗi tác tử được gán vào một node tại mỗi thời điểm.
- Các cạnh biểu diễn khả năng di chuyển và tiếp xúc giữa các node, đồng thời có thể bị điều chỉnh bởi các biện pháp can thiệp như giãn cách xã hội hoặc lockdown.

Mô hình sử dụng thư viện NetworkX để xây dựng và quản lý đồ thị mạng lưới.

b) Loại mạng lưới được sử dụng

Nếu không cung cấp mạng lưới sẵn, mô hình tự động tạo mạng Barabási–Albert, một dạng mạng scale-free thường được dùng để mô phỏng mạng xã hội thực tế. Đặc điểm của loại mạng này là:

- Có một số node trung tâm với số lượng kết nối lớn.
- Phản ánh hiện tượng "siêu lây nhiễm" trong dịch bệnh.

c) Ảnh hưởng của mạng lưới tới quá trình lây lan

Mạng lưới đóng vai trò quyết định trong động lực lây lan dịch bệnh:

- Các node đông người làm tăng xác suất lây nhiễm.
- Cấu trúc mạng ảnh hưởng đến tốc độ và phạm vi lan truyền.
- Các biện pháp giãn cách (lockdown) làm giảm khả năng di chuyển giữa các node, từ đó giảm tiếp xúc xã hội.

Nhờ thiết kế mạng lưới, mô hình có thể phản ánh được sự khác biệt giữa lây lan đồng đều và lây lan theo cụm, điều mà các mô hình SIR truyền thống khó thể hiện.

3.2.4 Thiết kế và chuẩn bị dữ liệu mô phỏng

Khác với các bài toán học máy truyền thống, trong đó mô hình được huấn luyện dựa trên các tập dữ liệu thu thập sẵn từ thế giới thực, dữ liệu trong đồ án này không tồn tại dưới dạng tập dữ liệu cố định. Thay vào đó, dữ liệu được sinh ra trực tiếp trong quá trình mô phỏng thông qua sự tương tác liên tục giữa mô hình mô phỏng dịch bệnh và tác tử học tăng cường.

Cụ thể, mỗi lần mô phỏng tương ứng với một episode huấn luyện, trong đó tác tử học tăng cường quan sát trạng thái của hệ thống, thực hiện hành động can thiệp và nhận phản hồi từ môi trường dưới dạng phần thưởng. Chuỗi các cặp trạng thái – hành động – phần thưởng – trạng thái tiếp theo được tạo ra trong quá trình này chính là dữ liệu huấn luyện cho mô hình học tăng cường.

Do đó, chất lượng dữ liệu huấn luyện phụ thuộc trực tiếp vào cách thiết kế mô hình mô phỏng, bao gồm cấu trúc mạng lưới tiếp xúc, tham số dịch bệnh, cơ chế tiêm vaccine và các biện pháp can thiệp. Nếu mô hình mô phỏng phản ánh hợp lý động lực lây lan dịch bệnh, dữ liệu sinh ra sẽ có ý nghĩa và giúp tác tử học được chính sách can thiệp hiệu quả. Ngược lại, một mô hình mô phỏng kém hợp lý có thể dẫn đến dữ liệu huấn luyện sai lệch và kết quả học không đáng tin cậy.

Vì lý do đó, trong đồ án này, việc thiết kế mô hình SIRV và môi trường mô phỏng không chỉ đóng vai trò mô tả bài toán, mà còn được xem là bước tiền xử lý dữ liệu quan trọng đối với bài toán học tăng cường. Toàn bộ quá trình huấn luyện được thực hiện theo hướng học trực tuyến (online learning), trong đó dữ liệu được sinh và sử dụng đồng thời trong suốt quá trình mô phỏng.

3.3 Thiết kế môi trường học tăng cường

Trong mô hình đề xuất, học tăng cường không được sử dụng để điều khiển hành vi của từng cá thể riêng lẻ, mà đóng vai trò tối ưu hóa chính sách can thiệp ở mức toàn cục. Do đó, việc thiết kế môi trường học tăng cường đóng vai trò then chốt, quyết định khả năng học, tính ổn định và ý nghĩa thực tiễn của kết quả thu được.

Để đảm bảo tính chuẩn hóa và khả năng mở rộng, môi trường học tăng cường được xây dựng theo chuẩn OpenAI Gym, trong đó mô hình mô phỏng dịch bệnh trên Mesa được "bao bọc" như một môi trường mà tác tử học tăng cường có thể quan sát, hành động và nhận phản hồi.

3.3.1 Xây dựng môi trường theo chuẩn OpenAI Gym

a) Lý do sử dụng OpenAI Gym

OpenAI Gym là một chuẩn giao diện phổ biến cho các bài toán học tăng cường, được sử dụng rộng rãi trong nghiên cứu và thực tiễn. Việc xây dựng môi trường theo chuẩn Gym mang lại các lợi ích sau:

- Chuẩn hóa giao diện giữa môi trường và thuật toán học tăng cường thông qua các hàm reset(), step(), render().

- Dễ dàng tích hợp với các thư viện học tăng cường hiện đại như Stable-Baselines3.
- Cho phép thay thế thuật toán RL mà không cần thay đổi logic mô phỏng.
- Tăng tính tái sử dụng và khả năng mở rộng của hệ thống.

Trong đồ án, môi trường Gym đóng vai trò trung gian giữa mô hình mô phỏng Mesa và tác tử học tăng cường, giúp tách biệt rõ ràng hai thành phần này.

b) Ánh xạ mô hình Mesa sang môi trường Gym

Mô hình mô phỏng dịch bệnh được xây dựng trên Mesa vốn hoạt động theo cơ chế step-based, trong đó mỗi bước tương ứng với một ngày mô phỏng. Cách hoạt động này rất phù hợp để ánh xạ sang môi trường Gym.

Quá trình ánh xạ được thực hiện như sau:

- Môi trường (Environment) trong Gym bao bọc một đối tượng mô hình Mesa.
- Mỗi lần gọi env.step(action) tương ứng với:
    - Tác tử học tăng cường lựa chọn một hành động đại diện cho mức độ can thiệp ở cấp độ toàn cục..
    - Mô hình Mesa cập nhật chính sách can thiệp tương ứng.
    - Mô phỏng dịch bệnh chạy một bước thời gian.
    - Thu thập trạng thái mới và tính phần thưởng.

Cách tiếp cận này cho phép học tăng cường tác động gián tiếp đến mô hình, thay vì điều khiển trực tiếp từng tác tử, phù hợp với bối cảnh bài toán chính sách công.

3.3.2 Không gian trạng thái (State Space)

a) Nguyên tắc thiết kế không gian trạng thái

Không gian trạng thái cần cung cấp cho tác tử học tăng cường đủ thông tin để ra quyết định, nhưng không quá chi tiết để tránh làm tăng độ phức tạp không cần thiết. Do RL

chỉ điều khiển chính sách can thiệp, trạng thái được thiết kế ở mức tổng hợp toàn cục, thay vì thông tin chi tiết của từng cá thể.

b) Các thông tin tác tử RL quan sát được

Trong mỗi bước mô phỏng, tác tử học tăng cường quan sát các thông tin sau:

- Số ca nhiễm đang hoạt động: Đây là chỉ số quan trọng nhất phản ánh mức độ nghiêm trọng của dịch bệnh tại thời điểm hiện tại.
- Tỷ lệ dân số đã được tiêm vaccine: Thể hiện mức độ bao phủ vaccine trong cộng đồng, ảnh hưởng trực tiếp đến khả năng lây lan trong tương lai.
- Thời điểm mô phỏng (ngày hiện tại): Thời gian đóng vai trò quan trọng vì:
    - Vaccine được triển khai theo thời gian.
    - Hiệu quả của các biện pháp can thiệp thay đổi theo giai đoạn dịch.

Các thông tin này được trích xuất trực tiếp từ mô hình Mesa sau mỗi bước mô phỏng.

c) Biểu diễn trạng thái

Các thông tin quan sát được ghép lại thành một vector trạng thái dạng số thực:

State = [số ca nhiễm chuẩn hóa, tỷ lệ đã tiêm, ngày mô phỏng chuẩn hóa]

Việc chuẩn hóa các giá trị giúp ổn định quá trình huấn luyện và tăng khả năng hội tụ của thuật toán học tăng cường. Cách biểu diễn này giúp giảm đáng kể kích thước không gian trạng thái, từ đó cải thiện độ ổn định và tốc độ hội tụ của thuật toán học tăng cường.

3.3.3 Không gian hành động (Action Space)

a) Thiết kế không gian hành động rời rạc

Không gian hành động được thiết kế ở dạng Discrete Action Space, trong đó mỗi hành động tương ứng với một mức độ can thiệp khác nhau. Cách thiết kế này giúp phản ánh sát các quyết định chính sách trong thực tế.

b) Các mức độ can thiệp

Tác tử học tăng cường có thể lựa chọn một trong bốn hành động sau:

- Hành động 0 – Không can thiệp: Hoạt động xã hội diễn ra bình thường, không áp dụng biện pháp hạn chế.
- Hành động 1 – Can thiệp nhẹ: Giảm một phần tiếp xúc xã hội, ví dụ hạn chế tụ tập đông người.
- Hành động 2 – Can thiệp trung bình: Áp dụng các biện pháp giãn cách mạnh hơn, giảm đáng kể khả năng tiếp xúc.
- Hành động 3 – Can thiệp mạnh (lockdown): Áp dụng biện pháp hạn chế nghiêm ngặt, giảm tối đa tiếp xúc xã hội.

c) Ý nghĩa của hành động

Mỗi hành động ảnh hưởng trực tiếp đến:

- Xác suất tiếp xúc giữa các tác tử,
- Khả năng lây lan virus trong mạng lưới,
- Chi phí xã hội được phản ánh trong hàm phần thưởng.

Cách thiết kế này cho phép tác tử RL học được sự đánh đổi giữa kiểm soát dịch bệnh và chi phí can thiệp.

3.3.4 Hàm phần thưởng (Reward Function)

a) Vai trò của hàm phần thưởng

Trong bài toán học tăng cường cho mô phỏng dịch bệnh, hàm phần thưởng đóng vai trò trung tâm trong việc định hướng hành vi của tác tử học tăng cường. Hàm phần thưởng không chỉ phản ánh mục tiêu kiểm soát dịch bệnh, mà còn thể hiện sự đánh đổi giữa lợi ích y tế và chi phí xã hội phát sinh từ các biện pháp can thiệp. Hàm phần thưởng là thành phần cốt lõi định hướng hành vi học của tác tử. Thiết kế hàm phần thưởng hợp lý giúp tác tử học được chiến lược can thiệp hiệu quả và ổn định. Do đó, việc thiết kế hàm phần thưởng cần đảm bảo tính hợp lý, ổn định và phù hợp với bối cảnh thực tế.

Khác với các bài toán học máy truyền thống sử dụng dữ liệu gán nhãn sẵn, trong đồ án này, dữ liệu huấn luyện được sinh ra trực tiếp từ quá trình mô phỏng. Vì vậy, hàm phần thưởng được xây dựng dựa trên các đại lượng quan sát được trong mô hình Mesa, phản ánh trạng thái toàn cục của hệ thống tại mỗi bước thời gian.

b) Các thành phần của hàm phần thưởng

Hàm phần thưởng được thiết kế dựa trên hai thành phần chính: chi phí xã hội do dịch bệnh và chi phí can thiệp từ các biện pháp kiểm soát.

- Chi phí xã hội do dịch bệnh:

Chi phí xã hội được sử dụng để biểu diễn mức độ tổn thất mà xã hội phải gánh chịu khi dịch bệnh lây lan. Trong mô hình, chi phí này được xấp xỉ thông qua số lượng tác tử đang ở trạng thái nhiễm bệnh (I) tại mỗi bước thời gian. Mỗi cá thể nhiễm bệnh được xem là một đơn vị gây tổn thất cho xã hội, bao gồm các hệ quả về sức khỏe cộng đồng, áp lực lên hệ thống y tế và gián đoạn các hoạt động kinh tế – xã hội.

Cụ thể, chi phí xã hội tại thời điểm ttt được xác định như sau:

$$C_{\text{social}}(t) = \alpha \cdot I(t) \qquad (3\text{-}1)$$

Trong đó: $C_{\text{social}}(t)$ là chi phí xã hội tại thời điểm t, phản ánh mức độ ảnh hưởng tiêu cực của dịch bệnh lên hệ thống; $I(t)$ là số lượng tác tử đang ở trạng thái nhiễm bệnh tại thời điểm t; α là hệ số phạt, phản ánh mức độ nghiêm trọng của mỗi ca nhiễm và được lựa chọn thông qua thực nghiệm; t là chỉ số thời gian của hệ thống mô phỏng.

Cách xây dựng này đảm bảo rằng khi số ca nhiễm tăng, chi phí xã hội tăng tương ứng, từ đó tạo áp lực buộc tác tử học tăng cường phải học cách giảm số ca nhiễm trong dài hạn.

- Chi phí can thiệp:

Bên cạnh chi phí do dịch bệnh, các biện pháp can thiệp như giãn cách xã hội hay phong tỏa cũng gây ra những tác động tiêu cực đến đời sống và kinh tế. Do đó, mỗi hành động

can thiệp của tác tử học tăng cường đều đi kèm một chi phí nhất định, nhằm phản ánh những tổn thất này.

Trong mô hình, không gian hành động được thiết kế rời rạc, bao gồm nhiều mức độ can thiệp khác nhau, từ không can thiệp đến can thiệp mạnh. Mỗi mức độ can thiệp được gán một chi phí cố định:

$$C_{\text{intervention}}(a_t) = \beta_{a_t} \qquad (3\text{-}2)$$

Trong đó: $C_{\text{intervention}}(a_t)$ là chi phí can thiệp tại thời điểm t; a_t là hành động được lựa chọn tại thời điểm ; β_{a_t} là chi phí tương ứng với mức độ can thiệp đó, với giá trị tăng dần theo mức độ nghiêm ngặt của biện pháp.

Thành phần này giúp ngăn chặn việc tác tử lạm dụng các biện pháp can thiệp mạnh trong suốt quá trình mô phỏng, từ đó buộc tác tử phải cân nhắc giữa hiệu quả kiểm soát dịch bệnh và chi phí xã hội phát sinh.

- Hàm phần thưởng tổng hợp:

Từ hai thành phần chi phí trên, hàm phần thưởng tại mỗi bước thời gian được xác định như sau:

$$R_t = -\left(C_{\text{social}}(t) + C_{\text{intervention}}(a_t)\right) \qquad (3\text{-}3)$$

Trong đó: R_t là phần thưởng tại thời điểm t được sử dụng trong bài toán học tăng cường; $C_{\text{social}}(t)$ là chi phí xã hội tại thời điểm t do các tác tử nhiễm bệnh gây ra; $C_{\text{intervention}}(a_t)$ là chi phí can thiệp tương ứng với hành động a_t được lựa chọn tại thời điểm t; dấu âm thể hiện mục tiêu của tác tử là tối thiểu hóa tổng chi phí, tương đương với việc tối đa hóa phần thưởng trong quá trình huấn luyện.

Hàm phần thưởng được thiết kế theo dạng giá trị âm nhằm phản ánh mục tiêu tối thiểu hóa tổng chi phí xã hội. Thông qua quá trình huấn luyện, tác tử học tăng cường sẽ học được chính sách can thiệp tối ưu, sao cho vừa hạn chế được sự lây lan của dịch bệnh, vừa tránh các biện pháp can thiệp quá mức không cần thiết.

c) Mục tiêu của thiết kế reward

Mục tiêu của hàm phần thưởng không phải là triệt tiêu hoàn toàn số ca nhiễm, mà là:

- Giữ số ca nhiễm ở mức chấp nhận được,
- Tránh áp dụng các biện pháp can thiệp quá mức trong thời gian dài.

d) Ý nghĩa học thuật của thiết kế reward

Thiết kế hàm phần thưởng trong đồ án cho phép mô hình hóa một cách đơn giản nhưng hiệu quả sự đánh đổi giữa kiểm soát dịch bệnh và chi phí xã hội. Cách tiếp cận này phù hợp với nhiều nghiên cứu học tăng cường hiện đại trong lĩnh vực dịch tễ học, nơi mục tiêu không chỉ là giảm số ca nhiễm mà còn đảm bảo tính bền vững của các chính sách can thiệp. Đồng thời, hàm phần thưởng được xây dựng đủ linh hoạt để có thể mở rộng trong tương lai, chẳng hạn như bổ sung chi phí tử vong, chi phí quá tải y tế hoặc tác động kinh tế chi tiết hơn.

3.3.5 Mô hình hóa quá trình lây nhiễm

Trong mô hình ABM, mỗi cá thể được biểu diễn như một tác tử độc lập, và quá trình lây nhiễm được mô hình hóa thông qua xác suất tiếp xúc cục bộ trên mạng lưới. Khi một tác tử ở trạng thái Susceptible tiếp xúc với một tác tử ở trạng thái Infected, khả năng bị lây nhiễm được xác định theo xác suất:

$$P_{\text{infect}} = \beta \cdot f(a_t) \qquad (3\text{-}4)$$

Trong đó: P_{infect} là xác suất lây nhiễm tại thời điểm t; β là xác suất lây nhiễm cơ bản của dịch bệnh; a_t là hành động can thiệp được lựa chọn tại thời điểm t; $f(a_t)$ là hệ số điều chỉnh phản ánh mức độ làm giảm tiếp xúc xã hội tương ứng với từng mức can thiệp.

Cách tiếp cận này cho phép mô hình phản ánh đặc trưng lây lan cục bộ của dịch bệnh, đồng thời linh hoạt điều chỉnh theo các chính sách can thiệp khác nhau mà không cần giải hệ phương trình vi phân.

3.3.6 Biểu diễn và chuẩn hóa trạng thái cho học tăng cường

Do tác tử học tăng cường chỉ ra quyết định ở mức chính sách toàn cục, trạng thái môi trường được thiết kế ở dạng tổng hợp và được biểu diễn dưới dạng vector số thực. Các thành phần trạng thái được chuẩn hóa như sau:

$$I_{\text{norm}}(t) = \frac{I(t)}{N}, \qquad V_{\text{norm}}(t) = \frac{V(t)}{N}, \qquad t_{\text{norm}} = \frac{t}{T_{max}} \tag{3-5}$$

Trong đó: $I_{\text{norm}}(t)$ là số lượng tác tử nhiễm bệnh đã được chuẩn hóa tại thời điểm t; $I(t)$là số lượng tác tử đang ở trạng thái nhiễm bệnh tại thời điểm t; $V_{\text{norm}}(t)$ là số lượng tác tử đã được tiêm chủng (hoặc đã phục hồi) sau khi chuẩn hóa; $V(t)$ là số lượng tác tử tương ứng tại thời điểm t; N là tổng số tác tử trong hệ thống; t là thời gian đã được chuẩn hóa; T_{max} là tổng thời gian mô phỏng.

Việc chuẩn hóa trạng thái giúp ổn định quá trình huấn luyện học tăng cường, đồng thời tăng khả năng hội tụ của thuật toán.

3.4 Thiết kế và tích hợp thuật toán học tăng cường

Sau khi xây dựng môi trường học tăng cường theo chuẩn OpenAI Gym, bước tiếp theo là lựa chọn và tích hợp thuật toán học tăng cường phù hợp để tác tử có thể học và tối ưu chính sách can thiệp. Thuật toán được lựa chọn cần đáp ứng được đặc thù của bài toán, đồng thời dễ triển khai và đánh giá trong khuôn khổ đồ án.

3.4.1 Lựa chọn thuật toán DQN

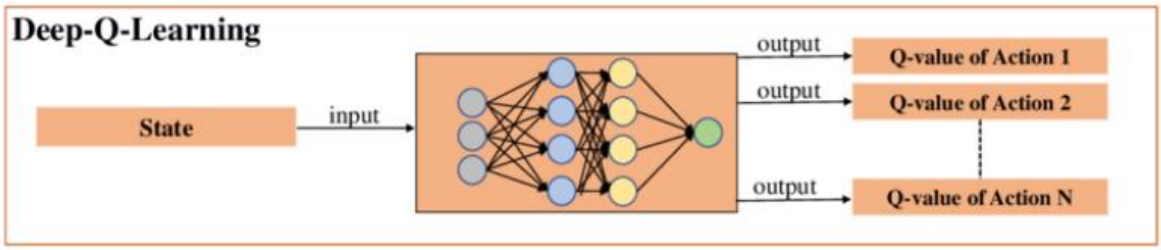
Thuật toán DQN được lựa chọn trong đồ án vì các lý do sau:

- Phù hợp với không gian hành động rời rạc: Bài toán chỉ có bốn hành động tương ứng với bốn mức độ can thiệp (từ không can thiệp đến lockdown mạnh), rất phù hợp với cấu trúc của DQN.
- Không yêu cầu mô hình môi trường: DQN là thuật toán model-free, không cần biết trước động lực bên trong của mô hình dịch bệnh, phù hợp với các hệ thống phức tạp như mô phỏng tác tử.

- Dễ triển khai và kiểm soát: So với các thuật toán policy-based phức tạp, DQN có cấu trúc tương đối đơn giản, dễ theo dõi quá trình học và phân tích kết quả.
- Phù hợp với mục tiêu thử nghiệm nền tảng Mesa: Mục tiêu của đồ án là khảo sát khả năng tích hợp học tăng cường với Mesa, do đó DQN là lựa chọn hợp lý để làm rõ hiệu quả của cách tiếp cận, trước khi mở rộng sang các thuật toán phức tạp hơn.

3.4.2 Kiến trúc mạng nơ-ron

a) Vai trò của mạng nơ-ron trong DQN



Hình 3.2 Kiến trúc thuật toán Deep Q-learning

Trong thuật toán DQN, hàm giá trị hành động Q(s,a) không được lưu trữ dưới dạng bảng truyền thống, mà được xấp xỉ bằng một mạng nơ-ron, gọi là Q-network. Q-network nhận đầu vào là trạng thái của môi trường và xuất ra giá trị Q tương ứng với từng hành động có thể thực hiện. Việc sử dụng mạng nơ-ron cho phép mô hình xử lý không gian trạng thái liên tục và có khả năng tổng quát hóa tốt hơn so với Q-learning cổ điển.

$$Q(s_t) = [Q(s_t, a_0), Q(s_t, a_1), Q(s_t, a_2), Q(s_t, a_3)] \quad (3\text{-}6)$$

Trong đó: $Q(s_t)$ là vector các giá trị hành động tại trạng thái s_t; $Q(s_t, a_i)$là giá trị Q tương ứng với hành động a_i tại trạng thái s_t ; s_t là trạng thái của hệ thống tại thời điểm t,được biểu diễn bởi vector [số ca nhiễm, tỷ lệ tiêm vaccine, thời gian mô phỏng]; a_0 là hành động không can thiệp; a_1 là hành động can thiệp nhẹ; a_2 là hành động can thiệp trung bình; a_3 là hành động phong tỏa nghiêm ngặt (lockdown mạnh).

b) Cấu trúc mạng nơ-ron

Mạng nơ-ron trong đồ án được thiết kế ở mức đơn giản nhưng đủ để học được mối quan hệ giữa trạng thái và hành động. Cấu trúc cơ bản bao gồm:

- Lớp đầu vào (Input Layer): Nhận vector trạng thái gồm các thành phần như:
    - Số ca nhiễm đang hoạt động,
    - Tỷ lệ dân số đã được tiêm vaccine,
    - Thời điểm mô phỏng.
- Các lớp ẩn (Hidden Layers): Một hoặc hai lớp ẩn với số lượng nơ-ron vừa phải, sử dụng hàm kích hoạt phi tuyến (ví dụ ReLU) để học các quan hệ phi tuyến trong dữ liệu.
- Lớp đầu ra (Output Layer): Số nơ-ron đầu ra bằng số hành động có thể thực hiện (4 nơ-ron), mỗi nơ-ron tương ứng với giá trị Q của một hành động.

Cách thiết kế này giúp mạng nơ-ron đủ linh hoạt để học chính sách hiệu quả mà không gây quá tải tính toán.

c) Vai trò của PyTorch

Thư viện PyTorch được sử dụng để:

- Xây dựng và huấn luyện mạng nơ-ron,
- Tự động tính gradient thông qua cơ chế autograd,
- Quản lý quá trình tối ưu hóa tham số.

Việc sử dụng PyTorch giúp quá trình triển khai DQN trở nên linh hoạt, dễ mở rộng và thuận tiện cho việc điều chỉnh kiến trúc hoặc tham số huấn luyện trong các thí nghiệm tiếp theo.

3.4.3 Quy trình huấn luyện tác tử học tăng cường

Quy trình huấn luyện DQN được thiết kế theo cấu trúc tiêu chuẩn của học tăng cường, gắn chặt với vòng lặp mô phỏng của Mesa.

a) Khởi tạo và reset môi trường

Mỗi episode huấn luyện bắt đầu bằng việc gọi hàm reset() của môi trường Gym:

- Mô hình Mesa được khởi tạo lại về trạng thái ban đầu,
- Số lượng ca nhiễm ban đầu được thiết lập,
- Bộ đếm thời gian mô phỏng được đặt về ngày đầu tiên.

Bước này đảm bảo mỗi episode là một kịch bản mô phỏng độc lập.

b) Vòng lặp huấn luyện theo episode

Trong mỗi episode, tác tử học tăng cường thực hiện các bước sau:

1. Quan sát trạng thái hiện tại từ môi trường.
2. Lựa chọn hành động theo chiến lược ε-greedy:
    - Với xác suất ε, tác tử chọn hành động ngẫu nhiên để thăm dò.
    - Với xác suất $1 - \varepsilon$ tác tử chọn hành động có giá trị Q cao nhất.
3. Thực hiện hành động bằng cách truyền mức độ can thiệp vào mô hình Mesa.
4. Mô phỏng tiến thêm một bước thời gian.
5. Nhận trạng thái mới và phần thưởng từ môi trường.

Quá trình này được lặp lại cho đến khi kết thúc episode hoặc đạt số bước mô phỏng tối đa.

c) Thu thập và lưu trữ trải nghiệm

Mỗi trải nghiệm thu được có dạng: (state, action, reward, next_state)

Các trải nghiệm này được lưu vào bộ nhớ trải nghiệm (replay buffer). Việc sử dụng replay buffer giúp:

- Giảm sự phụ thuộc giữa các mẫu huấn luyện liên tiếp,

- Ổn định quá trình học của mạng nơ-ron.
- Giúp làm mượt phân phối dữ liệu huấn luyện, hạn chế hiện tượng dao động mạnh trong quá trình cập nhật Q-network.

d) Cập nhật chính sách

Định kỳ, một minibatch các trải nghiệm được lấy ngẫu nhiên từ replay buffer để:

- Tính toán giá trị Q mục tiêu,
- Cập nhật trọng số của mạng nơ-ron thông qua lan truyền ngược.

Quá trình cập nhật này được lặp lại xuyên suốt quá trình huấn luyện, cho đến khi chính sách hội tụ hoặc đạt số episode mong muốn.

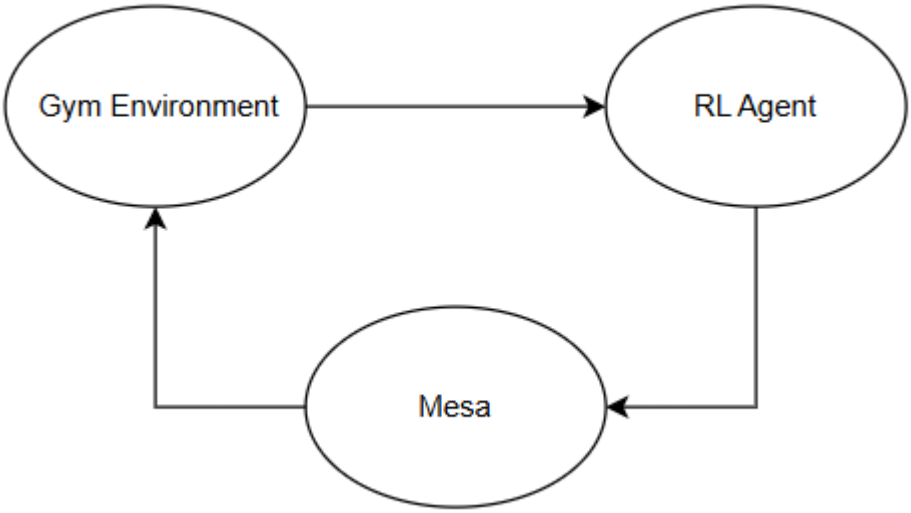
3.5 Quy trình mô phỏng và huấn luyện tổng thể

Sau khi xây dựng mô hình mô phỏng dịch bệnh, môi trường học tăng cường và thuật toán huấn luyện, hệ thống được tổ chức thành một chu trình khép kín giữa mô phỏng và học tăng cường. Trong chu trình này, diễn biến dịch bệnh được mô phỏng theo thời gian, trong khi chính sách can thiệp được tác tử học tăng cường liên tục điều chỉnh dựa trên trạng thái quan sát được từ môi trường.

Quy trình này phản ánh đúng bản chất của bài toán ra quyết định trong bối cảnh dịch bệnh, trong đó các quyết định chính sách không được áp đặt sẵn mà được tối ưu dần thông qua trải nghiệm và phản hồi từ môi trường mô phỏng.

3.5.1 Luồng dữ liệu tổng thể của mô hình

Luồng xử lý của mô hình có thể được mô tả theo chuỗi sau:



Hình 3.3 Sơ đồ luồng xử lý

Cụ thể:

- Mesa đóng vai trò là lõi mô phỏng, nơi diễn ra quá trình lây lan dịch bệnh giữa các tác tử trên mạng lưới.
- Gym environment đóng vai trò cầu nối, trừu tượng hóa mô hình Mesa thành một môi trường học tăng cường với trạng thái, hành động và phần thưởng.
- Tác tử học tăng cường (RL agent) quan sát trạng thái từ môi trường Gym, lựa chọn hành động can thiệp và gửi ngược lại cho mô hình Mesa.
- Mesa cập nhật trạng thái mô phỏng dựa trên hành động can thiệp và tiến hành bước mô phỏng tiếp theo.

Chu trình này được lặp lại theo từng bước thời gian và xuyên suốt quá trình huấn luyện.

3.5.2 Vai trò của từng thành phần trong chu trình

- Mô hình Mesa: Chịu trách nhiệm mô phỏng chi tiết hành vi của từng cá thể trong quần thể, bao gồm tiếp xúc, lây nhiễm, hồi phục và tiêm vaccine. Thành phần này đảm bảo tính vi mô và khả năng phản ánh các hiện tượng phát sinh từ tương tác cục bộ.

- Môi trường Gym: Đóng vai trò chuẩn hóa giao tiếp giữa mô phỏng và thuật toán học tăng cường. Gym xác định:
    - Trạng thái mà tác tử có thể quan sát,
    - Không gian hành động,
    - Cách tính phần thưởng.
- Tác tử học tăng cường: Là thành phần ra quyết định, không điều khiển từng cá thể riêng lẻ mà chỉ can thiệp ở mức chính sách vĩ mô (lockdown). Tác tử học cách cân bằng giữa việc giảm lây nhiễm và chi phí can thiệp.

3.5.3 Chu trình khép kín mô phỏng – học tập

Quy trình mô phỏng và huấn luyện được tổ chức theo hai vòng lặp lồng nhau: vòng lặp theo episode và vòng lặp theo từng bước thời gian (step).

Vòng lặp theo episode:

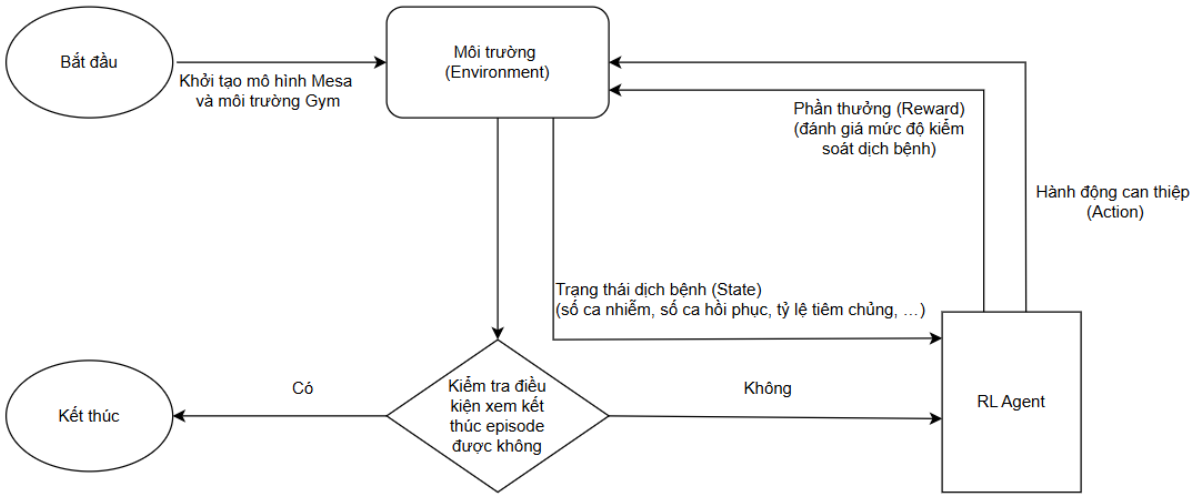
- Mỗi episode tương ứng với một kịch bản mô phỏng dịch bệnh kéo dài trong một khoảng thời gian xác định (ví dụ: 200 ngày mô phỏng).
- Tại đầu mỗi episode, môi trường Gym và mô hình Mesa được khởi tạo lại thông qua hàm reset(), đưa hệ thống về trạng thái ban đầu.

Vòng lặp theo bước thời gian (step): Trong mỗi step của một episode, chu trình sau được thực hiện:

1. Tác tử học tăng cường quan sát trạng thái hiện tại của hệ thống từ môi trường Gym.
2. Dựa trên chính sách hiện tại, tác tử lựa chọn một hành động can thiệp.
3. Hành động được truyền vào môi trường Gym và áp dụng gián tiếp lên mô hình Mesa.

4. Mô hình Mesa thực hiện một bước mô phỏng, tương ứng với một đơn vị thời gian.
5. Trạng thái mới của hệ thống và phần thưởng được tính toán và trả về cho tác tử.
6. Tác tử học tăng cường cập nhật chính sách dựa trên trải nghiệm thu được.

Chu trình step này được lặp lại cho đến khi đạt điều kiện kết thúc episode (ví dụ: hết số bước mô phỏng định trước hoặc dịch bệnh chấm dứt).



Hình 3.4 Sơ đồ chu trình khép kín mô phỏng - học tập giữa tác tử học tăng cường và môi trường mô phỏng dịch bệnh

Chu trình này cho phép chính sách can thiệp được học dần theo thời gian, phản ánh sự thích nghi của hệ thống trước các kịch bản dịch bệnh khác nhau.

3.6 Cài đặt mô hình và huấn luyện mô hình SIRV

3.6.1 Cài đặt môi trường mô phỏng và môi trường học tăng cường

Để mô hình mô phỏng dịch bệnh kết hợp học tăng cường có thể hoạt động ổn định và tái lập được kết quả, việc cài đặt môi trường thực thi đóng vai trò quan trọng. Trong đồ án này, toàn bộ quá trình mô phỏng và huấn luyện được triển khai trên môi trường Python, kết hợp các thư viện Mesa, OpenAI Gym và PyTorch (Bashline3).

a) Thiết lập môi trường thực thi

Mô hình được triển khai trên môi trường Python (phiên bản 3.13), có thể chạy trên máy cá nhân. Do quá trình huấn luyện học tăng cường sử dụng mạng nơ-ron, việc sử dụng GPU giúp tăng tốc đáng kể thời gian huấn luyện.

Trước khi huấn luyện, hệ thống kiểm tra thiết bị tính toán (CPU/GPU) và lựa chọn thiết bị phù hợp để thực thi mô hình. Trong trường hợp GPU khả dụng, PyTorch sẽ tự động sử dụng GPU để huấn luyện mạng Q-network; nếu không, hệ thống sẽ chuyển sang sử dụng CPU.

b) Cài đặt các thư viện cần thiết

Các thư viện chính được sử dụng trong đồ án bao gồm:

- Mesa: dùng để xây dựng mô hình mô phỏng dịch bệnh dựa trên tác tử.
- NetworkX: dùng để xây dựng và quản lý mạng lưới tiếp xúc xã hội giữa các tác tử.
- OpenAI Gym: dùng để chuẩn hóa môi trường học tăng cường.
- PyTorch: dùng để xây dựng và huấn luyện mạng nơ-ron trong thuật toán DQN.
- NumPy và Matplotlib: dùng cho xử lý số liệu và trực quan hóa kết quả mô phỏng.

Sau khi cài đặt các thư viện trên, môi trường sẵn sàng cho việc khởi tạo mô hình mô phỏng và huấn luyện tác tử học tăng cường.

c) Cài đặt môi trường mô phỏng dịch bệnh (Mesa)

Môi trường mô phỏng dịch bệnh được xây dựng dựa trên ví dụ “Virus on a Network” của Mesa và được mở rộng thành mô hình SIRV. Trong mô hình này:

- Mỗi tác tử đại diện cho một cá thể trong quần thể.
- Trạng thái dịch bệnh của tác tử được khởi tạo theo tỷ lệ ban đầu (đa số là Susceptible, một số ít là Infected).

- Mạng lưới tiếp xúc xã hội được tạo tự động bằng mô hình mạng Barabási–Albert nếu không có dữ liệu mạng đầu vào.

Các tham số mô phỏng chính được thiết lập ngay khi khởi tạo mô hình, bao gồm:

- Số lượng tác tử (quy mô dân số),
- Xác suất lây nhiễm cơ bản,
- Thời gian hồi phục,
- Hiệu quả vaccine và tốc độ tiêm chủng,
- Mức độ tương tác xã hội ban đầu.

Sau khi khởi tạo, mô hình Mesa có thể chạy độc lập từng bước thời gian để mô phỏng diễn biến dịch bệnh.

d) Cài đặt môi trường học tăng cường theo chuẩn OpenAI Gym

Để tích hợp học tăng cường, mô hình Mesa được bao bọc trong một lớp môi trường tuân theo chuẩn OpenAI Gym. Lớp môi trường này đóng vai trò trung gian giữa mô phỏng dịch bệnh và thuật toán học tăng cường.

Môi trường Gym được cài đặt với các thành phần chính sau:

- reset(self): Khởi tạo lại mô hình Mesa, thiết lập trạng thái ban đầu của dịch bệnh và đặt lại thời gian mô phỏng. Hàm này được gọi khi bắt đầu mỗi episode huấn luyện.
- step(self,action): Nhận hành động can thiệp từ tác tử học tăng cường, cập nhật chính sách can thiệp trong mô hình Mesa, chạy mô phỏng thêm một bước thời gian và trả về:
    - Trạng thái mới của hệ thống,
    - Phần thưởng tương ứng,
    - Cờ kết thúc episode (done).

```python
def reset(self):
    self.model = EpidemicModel(**self.model_params)
    obs = self.model.get_observation()
    return obs

def step(self, action):
    # apply action (lockdown level) and step one day
    self.model.step(action)
    obs = self.model.get_observation()
    reward = float(self.model.reward)
    done = False
    if self.model.step_count >= self.model_params.get('max_days', 365):
        done = True
    I = sum(1 for a in self.model.agents.values() if a.status == 'I')
    if I == 0:
        done = True
    info = {
        'cum_infected': self.model.cum_infected,
        'cum_vaccinated': self.model.cum_vaccinated,
        'day': self.model.step_count,
    }
    return obs, reward, done, info
```

Hình 3.5 Câu lệnh hàm reset và step

Trong đó, mỗi lần gọi step(action) tương ứng với một ngày mô phỏng trong mô hình dịch bệnh.

e) Liên kết môi trường mô phỏng và học tăng cường

Sau khi hoàn tất cài đặt, môi trường Gym bao bọc mô hình Mesa được sử dụng trực tiếp trong quá trình huấn luyện DQN. Tác tử học tăng cường không can thiệp vào hành vi của từng cá thể, mà chỉ điều chỉnh mức độ can thiệp xã hội ở mỗi bước thời gian.

3.6.2 Quy trình huấn luyện tác tử học tăng cường

Sau khi cài đặt hoàn chỉnh môi trường mô phỏng và môi trường học tăng cường, đồ án tiến hành xây dựng và thực hiện các kịch bản thí nghiệm nhằm đánh giá vai trò của học tăng cường trong việc tối ưu chính sách can thiệp dịch bệnh. Các thí nghiệm được chia thành hai nhóm chính: kịch bản không sử dụng học tăng cường và kịch bản có sử dụng

học tăng cường. Việc so sánh hai nhóm kịch bản này cho phép đánh giá trực tiếp hiệu quả của phương pháp đề xuất.

3.6.2.1 Kịch bản không sử dụng học tăng cường

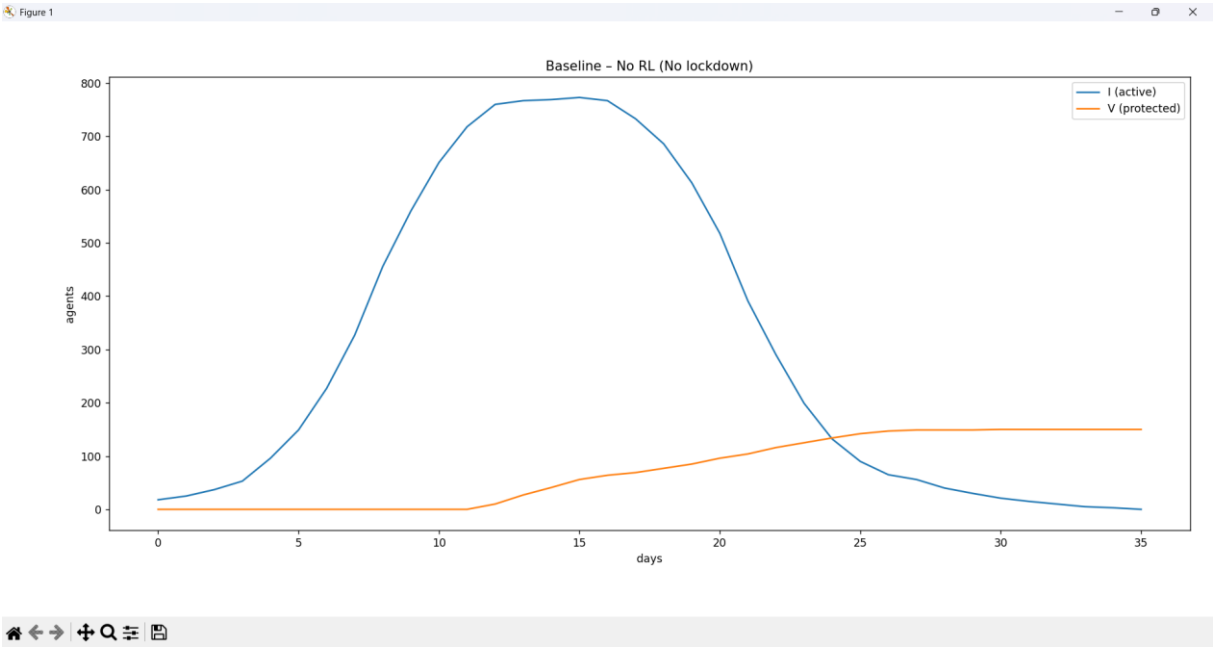
a) Tham số đầu vào

Trong kịch bản này, mô hình Mesa được chạy độc lập mà không có sự tham gia của tác tử học tăng cường. Chính sách can thiệp được thiết lập cố định trước khi mô phỏng và không thay đổi trong suốt quá trình chạy. Các tham số chính bao gồm:

- Số lượng tác tử: N = 1000
- Số ca nhiễm ban đầu: initial_infected = 10
- Xác suất lây nhiễm: p_transmission = 0.04
- Thời gian hồi phục: infectious_period = 14 ngày
- Tỷ lệ tiêm vaccine mỗi ngày: daily_capacity_fraction = 0.02
- Thời gian vaccine có hiệu lực: post_vacc_period_days = 12 ngày
- Không áp dụng biện pháp giãn cách hay lockdown (action = 0)
- Chương trình tiêm vaccine được triển khai theo năng lực cố định mỗi ngày

Các tham số này được giữ không đổi để tạo ra đường cơ sở (baseline) phục vụ so sánh.

b) Kết quả:



Hình 3.6 Diễn biến trong kịch bản không sử dụng học tăng cường

Bảng 3.1. Phân tích kết quả mô phỏng kịch bản không sử dụng học tăng cường (Baseline)

Đồ thị	**Hiện tượng quan sát được**	**Giải thích**
I (active)	- Số ca nhiễm tăng nhanh từ ngày 0 đến khoảng ngày 14–16 - Đạt đỉnh xấp xỉ 750–780 ca nhiễm đồng thời - Sau đó giảm dần và tiến về 0 vào cuối giai đoạn mô phỏng	- Giai đoạn đầu, phần lớn dân số chưa có miễn dịch nên tốc độ lây lan cao - Không tồn tại biện pháp can thiệp làm giảm tiếp xúc xã hội (không lockdown) - Khi số ca nhiễm tăng cao, nhiều cá nhân bước vào giai đoạn hồi phục và hình thành miễn dịch tự nhiên, làm số ca nhiễm giảm dần

V (protected)	- Gần bằng 0 trong khoảng 10–12 ngày đầu - Tăng đều sau ngày thứ 12 - Cuối mô phỏng bão hòa quanh 150 cá nhân được bảo vệ	- Vaccine không có hiệu lực tức thì mà cần thời gian sau tiêm - Chỉ những cá nhân chưa bị nhiễm mới có thể chuyển sang trạng thái bảo vệ - Do dịch bùng phát mạnh ở giai đoạn đầu, nhiều cá nhân bị nhiễm trước khi được tiêm, làm giảm hiệu quả tổng thể của chương trình tiêm vaccine

c) Nhận xét:

- Kịch bản không sử dụng học tăng cường dẫn đến đỉnh dịch cao và xuất hiện sớm
- Việc không có biện pháp can thiệp thích ứng khiến dịch lan nhanh trong giai đoạn đầu
- Chương trình tiêm vaccine tuy giúp giảm số ca về lâu dài nhưng không đủ để ngăn dịch bùng phát
- Tổng số cá nhân được bảo vệ thấp hơn đáng kể so với kịch bản có RL

Kịch bản baseline đóng vai trò là đường cơ sở (baseline) để so sánh với kịch bản có học tăng cường, từ đó làm nổi bật hiệu quả của việc áp dụng chính sách can thiệp thích ứng do tác tử RL điều khiển.

3.6.2.2 Kịch bản sử dụng học tăng cường

a) Tham số đầu vào

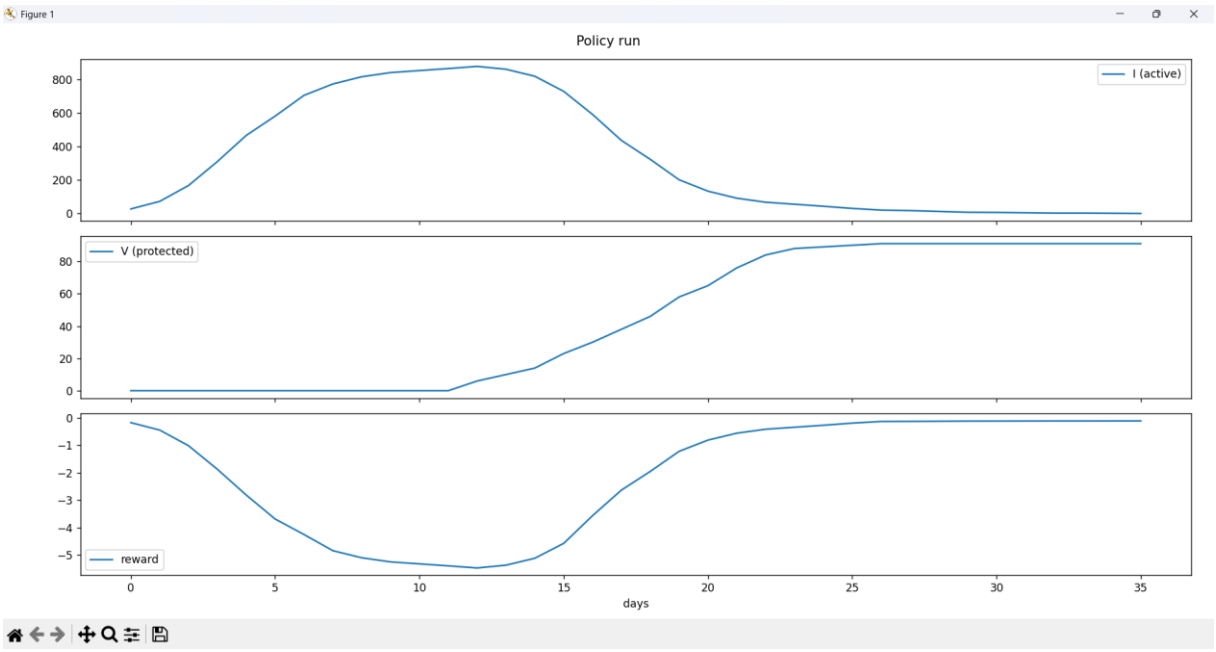
Trong kịch bản này, tác tử học tăng cường DQN được sử dụng để điều khiển chính sách can thiệp ở mức toàn cục. Ngoài các tham số dịch bệnh giống với kịch bản baseline, mô hình bổ sung thêm các tham số huấn luyện RL, bao gồm:

- Số lượng tác tử: N = 1000

- Số ca nhiễm ban đầu: initial_infected = 10
- Xác suất lây nhiễm: p_transmission = 0.04
- Thời gian hồi phục: infectious_period = 14 ngày
- Tỷ lệ tiêm vaccine mỗi ngày: daily_capacity_fraction = 0.02
- Thời gian vaccine có hiệu lực: post_vacc_period_days = 12 ngày
- Mức độ giảm nguy cơ nhiễm sau tiêm: post_vacc_infection_multiplier = 0.2
- Không gian hành động gồm 3 mức độ can thiệp:
    - Không can thiệp
    - Hạn chế một phần
    - Lockdown mạnh
- Thời gian mô phỏng tối đa mỗi episode: 35 ngày

  Mỗi episode tương ứng với một chu kỳ mô phỏng dịch

b) Kết quả



Hình 3.7 Diễn biến trong kịch bản sử dụng học tăng cường

Bảng 3.2 Phân tích kết quả mô phỏng kịch bản sử dụng học tăng cường (RL)

Đồ thị	**Hiện tượng quan sát được**	**Giải thích**
I (active)	- Số ca nhiễm tăng nhanh từ ngày 0 đến khoảng ngày 10 - Đạt đỉnh khoảng 800–900 ca - Sau đó giảm mạnh và tiến về 0	- Giai đoạn đầu dịch bùng phát do chưa có miễn dịch vaccine - Tác tử RL chưa áp dụng mức can thiệp mạnh - Khi RL tăng cường lockdown và vaccine bắt đầu phát huy hiệu quả, tốc độ lây nhiễm giảm đáng kể
V (protected)	- Bằng 0 trong khoảng 12 ngày đầu	- Vaccine không tạo miễn dịch tức thì

	- Tăng nhanh từ ngày 12 đến ngày 25 - Sau đó tiến tới trạng thái bão hòa (~90%)	- Sau 12 ngày kể từ thời điểm tiêm, các tác tử chưa nhiễm chuyển sang trạng thái miễn dịch hoàn toàn
Reward	- Giá trị phần thưởng âm sâu trong giai đoạn dịch bùng phát - Đạt giá trị thấp nhất khi số ca nhiễm đạt đỉnh - Tăng dần và tiệm cận 0 khi dịch được kiểm soát	- Hàm phần thưởng phạt mạnh khi số ca nhiễm cao - Phạt chi phí xã hội do lockdown kéo dài - Giá trị phần thưởng cải thiện khi hệ thống tiến tới trạng thái ổn định

c) Nhận xét

So với kịch bản không sử dụng học tăng cường, kịch bản có RL thể hiện rõ ưu điểm:

- Chính sách can thiệp mang tính thích ứng theo thời gian,
- Cân bằng tốt hơn giữa giảm số ca nhiễm và hạn chế chi phí xã hội,
- Không áp dụng lockdown cứng nhắc mà điều chỉnh linh hoạt theo trạng thái hệ thống.

Điều này cho thấy học tăng cường có tiềm năng lớn trong việc hỗ trợ ra quyết định chính sách trong các bài toán mô phỏng dịch bệnh phức tạp.

3.6.3 Thay đổi và khảo sát các tham số mô phỏng

Để kiểm tra tính ổn định và khả năng mở rộng của mô hình, các tham số sau được thay đổi trong các thí nghiệm:

- Số lượng tác tử: Thay đổi quy mô dân số nhằm đánh giá hiệu năng mô hình khi số lượng cá thể tăng lên.
- Xác suất lây nhiễm: Mô phỏng các chủng virus với mức độ lây lan khác nhau, từ nhẹ đến mạnh.
- Hiệu quả vaccine: Thay đổi xác suất bảo vệ của vaccine để phân tích vai trò của tiêm chủng trong việc kiểm soát dịch.

Việc thiết kế nhiều kịch bản và bộ tham số khác nhau giúp đồ án đánh giá mô hình một cách toàn diện, đồng thời làm nổi bật vai trò của học tăng cường trong việc hỗ trợ ra quyết định chính sách trong các hệ thống phức tạp.

3.7 So sánh và đánh giá

3.7.1 So sánh định tính

Bảng 3.3 So sánh hiệu quả kiểm soát dịch bệnh giữa mô hình không sử dụng RL và có sử dụng RL

Tiêu chí	**Không sử dụng RL (Baseline)**	**Có sử dụng RL**
Chính sách can thiệp	Cố định, không thay đổi theo thời gian	Thích ứng, thay đổi theo trạng thái dịch
Đỉnh số ca nhiễm (I)	Cao, xuất hiện sớm	Thấp hơn, được trì hoãn
Diễn biến dịch	Bùng phát nhanh rồi suy giảm	Được kiểm soát sớm và ổn định hơn
Số cá nhân được bảo vệ (V)	Tăng chậm, giá trị cuối thấp	Tăng sớm và đạt mức cao hơn

Lockdown	Không có hoặc áp dụng cứng nhắc	Áp dụng linh hoạt, theo nhu cầu
Khả năng thích nghi	Không có	Cao

3.7.2 So sánh định lượng dựa trên kết quả mô phỏng

Dựa trên các đồ thị I (active) và V (protected), có thể rút ra các nhận xét sau:

- Trong kịch bản không RL, số ca nhiễm tăng nhanh ngay từ giai đoạn đầu, đạt đỉnh cao trong thời gian ngắn do không có biện pháp làm giảm tiếp xúc xã hội.
- Trong kịch bản có RL, tác tử học tăng cường chủ động siết chặt can thiệp khi số ca nhiễm tăng, giúp làm phẳng đường cong dịch và giảm đáng kể đỉnh số ca nhiễm.
- Số cá nhân được bảo vệ trong mô hình có RL cao hơn so với baseline, do dịch được kiểm soát tốt hơn, tạo điều kiện cho vaccine phát huy hiệu quả.

3.7.3 Đánh giá vai trò của học tăng cường

So với mô hình không sử dụng học tăng cường, mô hình có RL thể hiện rõ ưu điểm:

- Khả năng thích ứng theo thời gian: Chính sách can thiệp được điều chỉnh liên tục dựa trên trạng thái hiện tại của dịch bệnh.
- Cân bằng đa mục tiêu: RL đồng thời giảm số ca nhiễm và hạn chế việc áp dụng lockdown kéo dài.
- Giảm phụ thuộc vào ngưỡng thủ công: Không cần xác định trước các ngưỡng cố định để kích hoạt can thiệp.

Trong khi đó, mô hình baseline đóng vai trò là đường cơ sở so sánh, giúp làm nổi bật hiệu quả của việc áp dụng học tăng cường trong bài toán điều khiển dịch bệnh.

3.7.4 Nhận xét tổng quát

- Kết luận:

- Mô hình không sử dụng học tăng cường phù hợp để mô phỏng diễn biến dịch bệnh tự nhiên, nhưng thiếu khả năng kiểm soát chủ động.
- Mô hình sử dụng học tăng cường cho thấy hiệu quả vượt trội trong việc kiểm soát dịch bệnh nhờ chính sách can thiệp thích ứng.
- Việc áp dụng học tăng cường giúp giảm đỉnh dịch, kéo dài thời gian bùng phát và tăng tỷ lệ cá nhân được bảo vệ.

Do đó, học tăng cường là một hướng tiếp cận tiềm năng cho các bài toán hỗ trợ ra quyết định trong kiểm soát dịch bệnh quy mô lớn.

- Vẫn tồn tại một số hạn chế:

- Mô hình dịch bệnh được xây dựng ở mức độ trừu tượng, chưa phản ánh đầy đủ các yếu tố xã hội phức tạp trong thực tế như hành vi cá nhân, mức độ tuân thủ quy định hay sự khác biệt giữa các khu vực;
- Không gian trạng thái của tác tử còn đơn giản, chủ yếu dựa trên các biến tổng hợp, chưa khai thác các đặc trưng chi tiết hơn của hệ thống;
- Thuật toán DQN có thể gặp khó khăn khi mở rộng sang không gian trạng thái hoặc không gian hành động lớn hơn, đặc biệt trong các bài toán quy mô lớn hoặc có tính liên tục.

Tuy nhiên, những hạn chế này đồng thời mở ra các hướng nghiên cứu và cải tiến trong tương lai, ví dụ như mở rộng mô hình trạng thái, áp dụng các thuật toán học tăng cường tiên tiến hơn hoặc tích hợp dữ liệu thực tế để tăng độ chính xác và khả năng ứng dụng của hệ thống.

CHƯƠNG 4 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

4.1 Kết luận

Trong đồ án này, em đã tiến hành nghiên cứu, xây dựng và đánh giá một hệ thống mô phỏng dịch bệnh dựa trên tác tử, kết hợp giữa nền tảng Mesa và các thuật toán học tăng cường. Trọng tâm của đồ án là khảo sát khả năng tích hợp học tăng cường vào mô hình mô phỏng dịch bệnh trên mạng lưới, thông qua việc mở rộng mô hình SIR truyền thống của Mesa thành mô hình SIRV, có xét đến vai trò của vaccine và các biện pháp can thiệp động.

Cụ thể, đồ án được xây dựng dựa trên ví dụ "Virus on a network" trong thư viện Mesa, trong đó mỗi cá thể được mô hình hóa như một tác tử độc lập, tương tác với các tác tử khác thông qua mạng lưới tiếp xúc. Trên cơ sở mô hình SIR gốc, em đã tiến hành cải tiến bằng cách bổ sung trạng thái Vaccinated (V), cho phép mô phỏng quá trình tiêm vaccine và tác động của vaccine đến xác suất lây nhiễm. Việc mở rộng này giúp mô hình phản ánh sát hơn bối cảnh dịch bệnh thực tế, đặc biệt là trong các đợt bùng phát như COVID-19 đã từng xảy ra trên thế giới và tại Việt Nam.

Bên cạnh đó, đồ án đã thiết kế và tích hợp một tác tử học tăng cường vào hệ thống mô phỏng, đóng vai trò điều khiển các chính sách can thiệp ở mức toàn cục, chẳng hạn như các mức độ lockdown khác nhau. Thay vì sử dụng các chính sách cố định được thiết kế thủ công, tác tử học tăng cường có khả năng quan sát trạng thái của hệ thống theo thời gian, thực hiện hành động can thiệp và tự điều chỉnh chính sách dựa trên phần thưởng nhận được từ môi trường mô phỏng.

Quá trình thực hiện đồ án bao gồm các bước chính:

- Nghiên cứu cơ sở lý thuyết về mô phỏng dựa trên tác tử, học tăng cường và mô hình dịch bệnh SIR/SIRV.
- Phân tích và cải tiến mô hình *virus_on_network* của Mesa, mở rộng từ SIR sang SIRV, đồng thời thiết kế lại các cơ chế lây nhiễm, hồi phục và tiêm vaccine.

- Xây dựng môi trường học tăng cường theo chuẩn OpenAI Gym, ánh xạ mô hình mô phỏng Mesa sang các thành phần trạng thái, hành động và phần thưởng.
- Lựa chọn và triển khai thuật toán học tăng cường DQN để huấn luyện tác tử điều khiển chính sách can thiệp.
- Thực hiện các kịch bản mô phỏng có và không sử dụng học tăng cường, thu thập dữ liệu và so sánh kết quả.

Kết quả mô phỏng và huấn luyện cho thấy việc tích hợp học tăng cường vào mô hình mô phỏng dịch bệnh là khả thi và mang lại nhiều lợi ích. Tác tử học tăng cường có khả năng học được các chính sách can thiệp thích nghi theo diễn biến dịch bệnh, giúp giảm số ca nhiễm trong khi vẫn cân bằng được chi phí can thiệp. So với các kịch bản sử dụng chính sách cố định, mô hình có học tăng cường thể hiện tính linh hoạt cao hơn và phản ứng tốt hơn trước các thay đổi của trạng thái hệ thống.

Thông qua đồ án này, em đã làm rõ được tiềm năng của việc kết hợp mô phỏng tác tử và học tăng cường trong nghiên cứu các bài toán phức tạp, đặc biệt là các bài toán liên quan đến dịch bệnh truyền nhiễm. Hệ thống đề xuất không chỉ có giá trị học thuật trong việc thử nghiệm nền tảng Mesa với học tăng cường, mà còn có thể được xem là một hướng tiếp cận có tiềm năng ứng dụng trong nghiên cứu và hỗ trợ ra quyết định về chính sách y tế trong tương lai.

4.2 Hướng phát triển

Mặc dù đồ án đã đạt được những kết quả bước đầu khả quan, hệ thống hiện tại vẫn còn một số hạn chế và nhiều hướng phát triển tiềm năng có thể tiếp tục nghiên cứu trong tương lai.

- Mở rộng và làm phong phú mô hình dịch bệnh: Mô hình SIRV hiện tại mới chỉ xét đến một số yếu tố cơ bản như lây nhiễm, hồi phục và tiêm vaccine. Trong tương lai, có thể mở rộng mô hình bằng cách bổ sung các trạng thái và tham số khác như tái nhiễm, suy giảm miễn dịch theo thời gian, hoặc phân biệt mức độ hiệu quả của các loại vaccine khác nhau. Điều này sẽ giúp mô hình phản ánh sát hơn diễn biến dịch bệnh trong thực tế.

- Nâng cao không gian trạng thái và hành động của tác tử học tăng cường: Hiện tại, tác tử học tăng cường chỉ quan sát một số thông tin tổng quát và điều khiển các mức độ can thiệp rời rạc. Các nghiên cứu tiếp theo có thể mở rộng không gian trạng thái để bao gồm nhiều thông tin chi tiết hơn, chẳng hạn như phân bố trạng thái theo từng khu vực của mạng lưới, đồng thời thiết kế không gian hành động phong phú hơn, kết hợp giữa lockdown, tiêm vaccine và các biện pháp can thiệp khác.

- Thử nghiệm các thuật toán học tăng cường nâng cao: Đồ án hiện tại sử dụng thuật toán DQN do phù hợp với không gian hành động rời rạc và dễ triển khai. Trong tương lai, có thể thử nghiệm các thuật toán tiên tiến hơn như PPO, A2C hoặc các phương pháp học tăng cường đa tác tử (Multi-Agent Reinforcement Learning) để đánh giá hiệu quả trong các kịch bản phức tạp hơn.

- So sánh với dữ liệu thực tế: Một hướng phát triển quan trọng là hiệu chỉnh và kiểm chứng mô hình bằng cách so sánh kết quả mô phỏng với dữ liệu dịch bệnh thực tế, chẳng hạn như dữ liệu COVID-19 theo thời gian. Điều này sẽ giúp đánh giá mức độ tin cậy của mô hình và khả năng ứng dụng trong thực tiễn.

- Xây dựng công cụ trực quan hóa và hỗ trợ ra quyết định: Trên cơ sở mô hình đã xây dựng, có thể phát triển thêm các công cụ trực quan hóa và dashboard, giúp người dùng dễ dàng theo dõi diễn biến dịch bệnh và tác động của các chính sách can thiệp. Đây là bước quan trọng để đưa mô hình từ nghiên cứu học thuật sang các ứng dụng hỗ trợ ra quyết định.

Nhìn chung, những hướng phát triển trên không chỉ giúp hoàn thiện hệ thống hiện tại mà còn mở ra nhiều cơ hội nghiên cứu sâu hơn về việc kết hợp mô phỏng tác tử và học tăng cường. Đây là một hướng tiếp cận giàu tiềm năng, có thể đóng góp tích cực cho các nghiên cứu liên ngành trong lĩnh vực khoa học dữ liệu, trí tuệ nhân tạo và mô phỏng các hệ thống phức tạp.

TÀI LIỆU THAM KHẢO

[1] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.

[2] Mnih, V., Kavukcuoglu, K., Silver, D., et al. (2015). *Human-level control through deep reinforcement learning*. Nature, 518, 529–533.

[3] Masad, D., & Kazil, J. (2015). Mesa: An agent-based modeling framework. *Proceedings of the 14th Python in Science Conference (SciPy 2015)*, 53–60.

[4] Mesa Development Team. *Mesa: Agent-Based Modeling in Python*. https://mesa.readthedocs.io

[5] Mesa Documentation. *Virus on Network Example*. https://mesa.readthedocs.io/latest/examples/basic/virus_on_network.html

[6] Raffin, A., Hill, A., Gleave, A., et al. (2021). *Stable-Baselines3: Reliable Reinforcement Learning*.

[7] Wilensky, U., & Rand, W. (2015). *An Introduction to Agent-Based Modeling*. MIT Press.

[8] Brockman, G., Cheung, V., Pettersson, L., et al. (2016). *OpenAI Gym*

[9] NetworkX Developers. *NetworkX Documentation*. https://networkx.org/documentation

[10] Kermack, W. O., & McKendrick, A. G. (1927). *A Contribution to the Mathematical Theory of Epidemics*. Proceedings of the Royal Society A.

[11] Keeling, M. J., & Rohani, P. (2008). *Modeling Infectious Diseases in Humans and Animals*. Princeton University Press.

[12] Libin, P.J.K., Moonens, A., Verstraeten, T., Perez-Sanjines, F., N. Hens, A. Nowé & P. Lemey. *Deep reinforcement learning for large-scale epidemic control*. ALA2020 Conference Paper.

[13] Ohi, A.Q., M.F. Mridha, M.M. Monowar & M.A. Hamid. *Exploring optimal control of epidemic spread using reinforcement learning*. *Scientific Reports*, 10:22106 (2020).

[14] Hà Nội University of Public Health (2022). *Thực trạng tiêm chủng vaccine phòng COVID-19 của đối tượng từ 5 tuổi, thành phố Hà Nội năm 2022*.